

Contents

1	从零构建 MicroClaw	23
1.1	第 1 章 为什么是 MicroClaw：从聊天机器 人到执行型 Agent	23
1.1.1	1.1 从“问答”到“执 行”	24
1.1.2	1.2 MicroClaw 的 目标与非目标 .	26
1.1.3	1.3 项目演进脉络 与关键里程碑 .	29
1.1.4	1.4 本章小结 . .	31
1.1.5	实践误区速览 .	32
1.2	第 2 章 架构总览：渠道无 关核心 + 平台适配器 .	32

1.2.1	2.1 系统分层与主 数据流	33
1.2.2	2.2 AppState 与 核心模块装配 .	35
1.2.3	2.3 多渠道一致性 与差异化处理 .	37
1.2.4	2.4 本章小结 .	39
1.2.5	实践误区速览 .	39
1.3	第 3 章 Agent Loop 全景： 一次请求如何完成	40
1.3.1	3.1 输入归一化与 会话恢复	40
1.3.2	3.2 系统提示词构 建与上下文压 缩	42

1.3.3	3.3 tool_use / tool_result 迭代机 制	44
1.3.4	3.4 失败、重试与 边界条件	46
1.3.5	3.5 本章小结 .	48
1.3.6	源码片段与图 示	49
1.3.7	实践误区速览 .	51
1.4	第 4 章 Agent Loop 深潜： 状态机、事件流与可恢复 性	52
1.4.1	4.1 stop_reason 驱动的状态转 移	52
1.4.2	4.2 流式输出与事 件总线	55

1.4.3	4.3 最大迭代上限 与反失控设计 . 57
1.4.4	4.4 会话持久化与 跨轮次连续执 行 58
1.4.5	4.5 本章小结 . 60
1.4.6	源码片段与图 示 61
1.4.7	实践误区速览 . 63
1.5	第 5 章 工具系统设计：统 一抽象与可扩展执行 .. 64
1.5.1	5.1 Tool Trait 与 注册中心 64
1.5.2	5.2 内建工具分类 与边界 65
1.5.3	5.3 子代理工具集 裁剪 67

1.5.4	5.4 工具开发模板 与质量门禁 ...	69
1.5.5	5.5 本章小结 ..	71
1.5.6	源码片段与图 示	72
1.5.7	实践误区速览 ..	74
1.6	第 6 章 安全机制：风险分 级、审批门与权限模 型	75
1.6.1	6.1 Tool Risk 与执 行策略标签 ...	75
1.6.2	6.2 高风险工具双 阶段审批	77
1.6.3	6.3 聊天作用域授 权与 control_chat ..	78

1.6.4	6.4 Web Auth 与 scopes 设计 ..	80
1.6.5	6.5 本章小结 ..	82
1.6.6	源码片段与图示	83
1.6.7	实践误区速览 ..	85
1.7	第 7 章 Sandbox 机制： 隔离执行与失败策略 ..	85
1.7.1	7.1 Off / All 模式 与运行时路由 ..	86
1.7.2	7.2 DockerSandbox 资源与网络约束	87
1.7.3	7.3 挂载路径、符号链接与白名单防护	89

1.7.4	7.4	
		require_runtime
		与 fail-open /
		fail-closed ... 90
1.7.5	7.5	本章小结 . 92
1.7.6		源码片段与图
		示 94
1.7.7		实践误区速览 . 97
1.8	第 8 章	记忆系统：文件记
		忆 + 结构化记忆的分层模
		型 98
1.8.1	8.1	AGENTS.md
		持久化记忆 ... 98
1.8.2	8.2	SQLite 结构
		化记忆与生命周
		期 99

1.8.3	8.3 Reflector 提取与记忆质量闸门	101
1.8.4	8.4 语义检索与 token 预算注入	102
1.8.5	8.5 本章小结 .	104
1.8.6	源码片段与图示	105
1.8.7	实践误区速览 .	107
1.9	第 9 章 Todo、计划与执行编排	108
1.9.1	9.1 计划先行的执行哲学	108
1.9.2	9.2 todo_read / todo_write 协议实践	110

1.9.3	9.3 多步骤任务的 可观测推进 . . .	111
1.9.4	9.4 本章小结 .	113
1.9.5	实践误区速览 .	113
1.10	第 10 章 定时任务系统： 从一次性触发到持续自动 化	114
1.10.1	10.1 调度模型与 Cron 约定	114
1.10.2	10.2 Scheduler 与 Agent Loop 的耦 合点	115
1.10.3	10.3 DLQ 与任务 恢复机制	117
1.10.4	10.4 本章小结 .	118
1.10.5	源码片段与图 示	119

1.10.6	实践误区速览 .	121
1.11	第 11 章 多渠道适配层： Telegram、Discord、 Web 的共性与差异 . .	122
1.11.1	11.1 渠道路由与消 息模型	122
1.11.2	11.2 长消息分片与 传输约束	123
1.11.3	11.3 统一核心与适 配器扩展策略 .	124
1.11.4	11.4 本章小结 .	126
1.11.5	实践误区速览 .	126
1.12	第 12 章 Web 控制面与可 观测性	127
1.12.1	12.1 Web API 安全 面与配置自检 .	127

1.12.2	12.2 使用量、记忆 与稳定性指标	.129
1.12.3	12.3 运行手册与 SLO 告警闭 环	 130
1.12.4	12.4 本章小 结	 132
1.12.5	源码片段与图 示	 133
1.12.6	实践误区速览	.135
1.13	第 13 章 配置体系与设计 决策：每个参数背后的工 程取舍	 135
1.13.1	13.1 配置装载、默 认值与兼容策 略	 136

1.13.2	13.2 关键参数组逐 项解读	137
1.13.3	13.3 典型部署配置 与风险画像 . .	145
1.13.4	13.4 本章小 结	148
1.13.5	源码片段与图 示	149
1.13.6	实践误区速览 .	151
1.14	第 14 章 从代码到发布： 测试、升级、运维与路线 图	152
1.14.1	14.1 测试基线与稳 定性烟测	152
1.14.2	14.2 升级路径、回 滚策略与发布节 奏	154

1.14.3	14.3 技术债与下一阶段演进方向	.155
1.14.4	14.4 本章小结	 157
1.14.5	实践误区速览	.158
1.15	第 15 章 源码结构化导读： 从仓库树到执行路径	. 158
1.15.1	15.1 仓库分层阅读法	 159
1.15.2	15.2 crates 级别的职责边界	. . 160
1.15.3	15.3 src/ 主模块 导读	 161
1.15.4	15.4 工具模块逐项 导读	 166
1.15.5	15.5 文档与源码联 动阅读法	 169

1.15.6	15.6 阅读与改造的 实践清单	170
1.15.7	15.7 本章小结 .	171
1.15.8	源码片段与图 示	173
1.15.9	实践误区速览 .	175
1.16	第 16 章 安全深水区：威 胁建模与防护决策 ...	176
1.16.1	16.1 资产识别：到 底在保护什么 .	176
1.16.2	16.2 攻击面清单： 从输入到执行 .	178
1.16.3	16.3 典型威胁场景 与对策	179
1.16.4	16.4 防护策略优先 级模型	182

1.16.5	16.5 安全评审模 板	183
1.16.6	16.6 安全运营建 议	184
1.16.7	16.7 本章小 结	185
1.16.8	源码片段与图 示	186
1.16.9	实践误区速览	.188
1.17	第 17 章 Sandbox 实战与 攻防：部署、诊断与演 练	189
1.17.1	17.1 三种环境的沙 箱模板	189
1.17.2	17.2 上线前验证清 单	191

1.17.3	17.3 典型故障与排 障流程	192
1.17.4	17.4 攻防演练案例 (10 例)	194
1.17.5	17.5 沙箱策略演进 建议	196
1.17.6	17.6 本章小 结	197
1.17.7	源码片段与图 示	198
1.17.8	实践误区速 览	200
1.18	第 18 章 Agent Loop 案例 工坊：30 个任务如何收 敛	201
1.18.1	18.1 使用说明 .	201
1.18.2	18.2 案例集 .	202

1.18.3	18.3 模板化执行建议	217
1.18.4	18.4 本章小结	217
1.18.5	源码片段与图示	218
1.18.6	实践误区速览	220
1.19	第 19 章 配置项设计百科： 意图、风险与反模式 .	220
1.19.1	19.1 阅读方式	220
1.19.2	19.2 LLM 组 .	221
1.19.3	19.3 上下文与记忆组	225
1.19.4	19.4 路径与隔离组	228

1.19.5	19.5 Sandbox 组	231
1.19.6	19.6 Web 控制面 组	236
1.19.7	19.7 渠道与权限 组	240
1.19.8	19.8 语音、技能与 扩展组	243
1.19.9	19.9 费用与可观测 组	245
1.19.10	19.10 配置治理总 原则	246
1.19.11	19.11 本章小 结	247
1.19.12	源码片段与图 示	248

1.19.13	实践误区速 览	250
1.20	第 20 章 事故复盘与演练： 从告警到恢复	251
1.20.1	20.1 复盘方 法	251
1.20.2	20.2 事故案例 (20 例)	252
1.20.3	20.3 演练计划 (季度版) ...	263
1.20.4	20.4 复盘文化建 议	264
1.20.5	20.5 本章小 结	264
1.20.6	源码片段与图 示	265

1.20.7	实践误区速 览	267
1.21	第 21 章 全书总结：把 Agent 系统做成工程系 统	268
1.21.1	源码片段与图 示	271
1.21.2	实践误区速 览	273
1.22	第 22 章 实战练习题库： 从入门到进阶的工程训练 营	273
1.22.1	22.1 练习目标与方 法	274
1.22.2	22.2 训练地图 (图示)	275

1.22.3	22.3 基础营 (6 练)	276
1.22.4	22.4 进阶营 (8 练)	282
1.22.5	22.5 实战营 (8 练)	288
1.22.6	22.6 关键源码片 段 (练习速 查)	294
1.22.7	22.7 本章小 结	296
1.22.8	实践误区速 览	297
1.23	第 23 章 设计决策备忘录： 真实 ADR 清单与证据 链	297

1.23.1	23.1 使用说 明	298
1.23.2	23.2 核心 ADR (架构层) ...	298
1.23.3	23.3 核心 ADR (安全与隔离 层)	303
1.23.4	23.4 核心 ADR (记忆与调度 层)	307
1.23.5	23.5 核心 ADR (可观测与运维 层)	311
1.23.6	23.6 关键代码证 据片段	314
1.23.7	23.7 图示与定 位	317

1.23.8	23.8 本章小结	319
1.23.9	实践误区速览	319
1.24	附录	320
1.24.1	附录 A 术语表	320
1.24.2	附录 B 工具清单与风险等级速查	323
1.24.3	附录 C 默认配置项速查表	328
1.24.4	附录 D 参考资料与代码索引 ..	332

1 从零构建 MicroClaw

1.1 第 1 章 为什么是 Micro-Claw：从聊天机器人到执行型 Agent

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.1.1 从“问答”到“执行”

多数聊天机器人在系统设计上遵循同一条短路径：接收用户文本，拼接提示词，调用模型，返回文本。这个模式在问答类场景非常高效，但在工程任务上会很快碰到瓶颈。

第一类瓶颈是“动作缺失”。用户说“帮我查这个仓库里所有超时

配置”，仅靠生成文本无法完成真实检索动作；机器人需要能读文件、跑命令、过滤结果。第二类瓶颈是“过程不可追踪”。用户说“先列计划再执行”，传统 bot 只能输出一个计划文本，无法保证后续执行严格对齐。第三类瓶颈是“状态丢失”。多轮对话中上下文很快过长，系统在压缩时常把关键执行痕迹丢掉，导致下一轮重复劳动。

MicroClaw 的切入点是把“聊天界面”视为任务入口，把“执行系统”视为产品核心。它不是让模型在文本里扮演 shell，而是把 shell、文件系统、网页检索、调度器、记忆系统做成明确的工具接口，再由

Agent Loop 驱动这些接口完成闭环。

其价值不在“能调用多少工具”，而在“能否稳定完成任务”。稳定完成任务至少意味着四点：

1. 行为可解释：每次执行都有可检查的工具调用路径。
2. 状态可恢复：服务重启后，会话与任务不丢失。
3. 风险可控制：高风险工具有审批和策略边界。
4. 结果可复盘：失败时能知道失败在哪一层。

因此，MicroClaw 不是在“增强聊天”，而是在“重写执行面”。这也是后文会反复出现的一条主线：模

型负责决策，运行时负责约束与落地。

1.1.2 1.2 MicroClaw 的目标与非目标

从代码和文档可以看到，项目在目标定义上相对克制。它追求的是工程可用，而不是研究型“全能体”。

核心目标可归纳为五类：

1. 多渠道一致执行：Telegram、Discord、Web 共享同一 Agent Loop。
2. 工具优先而非文本优先：需要执行时必须通过工具，不靠“描述式完成”。
3. 状态持久化：消息、会话、任务、记忆都落盘，可续跑。

4. 可运维：有 Runbook、有 SLO 指标、有自检接口。
5. 可演进：通过工具和技能扩展能力，而不是分叉执行核心。

对应地，MicroClaw 也明确了非目标：

1. 不是通用低代码平台：不提供大而全的可视化流程编排器。
2. 不是多租户企业权限系统：当前认证授权在逐步完善中（见 RFC）。
3. 不是“零风险自动执行器”：默认配置仍强调上手成本和可用性平衡。

这个目标/非目标边界很关键。很多 Agent 项目失败，不是技术做不

到，而是目标过宽、边界含糊，最终在体验、安全、可维护性上同时失分。MicroClaw 的策略是“先做少而硬的核心”，例如围绕 Agent Loop、工具运行时、记忆体系和调度器建立主干，再逐层补控制面和治理能力。

1.1.3 1.3 项目演进脉络与关键里程碑

从 website/blog 与 docs 的材料看，项目演进大致经历了三个阶段。

阶段一：可用性优先。初期重点是把“聊天入口 + 工具执行 + 基础持久化”打通，让系统真正可跑。这个阶段常见设计是默认路径尽量短，

例如沙箱默认关闭、配置尽量少，以降低首次部署摩擦。

阶段二：可靠性优先。随着功能增多，系统开始补齐长期运行能力：会话恢复、上下文压缩、调度任务、失败记录、DLQ、运行报告。这里的关键不是“新增一个功能”，而是把功能放进同一稳定闭环。

阶段三：治理与平台化优先。近期提交和 RFC 显示，项目进入“可控扩展”阶段：Auth scopes、Hooks 事件模型、配置自检、指标统一命名、升级指南等都在收敛。换句话说，系统开始为规模化使用预留规则空间。

一个值得注意的取舍是：项目没有采用“每个渠道独立智能体”的常见方式，而是坚持共享核心。这样做让开发者在新增渠道时主要处理 I/O 适配，不需要复制 Agent Loop，避免策略漂移。

另一个关键里程碑是“结构化记忆 + Reflector”。这意味着系统从“把记忆写在文件里”升级为“可检索、可去重、可追踪”的记忆层，并且通过后台任务持续维护质量。这种能力在长周期任务里非常重要，因为用户真正关心的是“下周它还记得并做对”。

1.1.4 1.4 本章小结

本章建立了全书起点：MicroClaw 的核心不是聊天，而是执行；它的价值在于把模型决策嵌入一个有状态、有边界、可恢复的运行时。

下一章将进入系统结构层，解释“渠道无关核心 + 平台适配器”如何在代码中落地，以及这个分层如何直接影响后续安全、扩展和运维成本。

1.1.5 实践误区速览

1. 只停留在概念层，不回到代码和配置验证理解。
2. 把“多渠道支持”理解为“多套核心逻辑并行”。

3. 过早讨论功能扩张, 而忽视边界和目标收敛。

1.2 第2章 架构总览：渠道无关核心 + 平台适配器

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.2.1 2.1 系统分层与主数据流

MicroClaw 的总体结构可以概括为四层：接入层、执行层、状态层、后台层。

接入层负责“进出站协议”，对应 `src/channels/*` 与 `src/web.rs`。它处理不同平台的消息事件、格式约束、身份字段和回包方

式。执行层是核心，主要在 `src/agent_engine.rs`，负责循环调用模型与工具。状态层由存储和配置组成，包括会话、消息、任务、记忆、指标。后台层包括 `scheduler` 与 `reflector`，处理定时与记忆维护。

这四层之间的数据流遵循一个稳定路径：

1. 渠道收到用户事件，归一化为内部请求。
2. 请求进入共享 Agent Loop。
3. Agent Loop 按需调用 Tool-Registry。
4. 工具执行结果回流到 Agent Loop，直到模型结束。

5. 结果通过渠道适配器发回, 并落库。
6. 后台任务周期性读取状态层, 触发下一轮执行或维护。

该路径的重要点在于“统一核心, 不统一外壳”。也就是说, 渠道差异被隔离在入口出口, 任务逻辑尽量统一在执行层。这直接降低了多平台维护成本。

1.2.2 2.2 AppState 与核心模块装配

在运行时层面, MicroClaw 通过一个集中状态容器把关键能力装配到一起。虽然不同模块位于不同 crate 或目录, 但调用关系收敛到统一状态对象。

这个装配思路有三个工程优势：

1. 依赖关系可见：LLM、DB、工具注册、渠道注册、记忆服务、hooks 都在同一图里。
2. 生命周期清晰：启动阶段初始化，运行阶段共享，退出阶段可控回收。
3. 测试边界明确：单元测试可替换局部模块，集成测试可走完整链路。

例如工具系统初始化时，需要配置 `working_dir`、`working_dir_isolation`、`sandbox` 路由器、数据库句柄和渠道注册器。把这些依赖显式注入到 `Tool-Registry`，比在工具内部“隐式读取

全局单例”更容易做策略控制和错误定位。

另一个装配细节是“默认值落点”。配置默认值集中定义，文档又由脚本生成，减少“代码默认值”和“文档默认值”漂移。对于运行时项目，这类一致性比表面功能更重要，因为运维事故常常来自默认行为误判。

1.2.3 2.3 多渠道一致性与差异化处理

“多渠道一致性”不等于“所有渠道行为一模一样”。MicroClaw 的做法是把一致性放在语义层，把差异化放在传输层。

语义层一致性主要体现在：

1. 同一用户请求都走相同 Agent Loop。
2. 同一工具调用语义一致。
3. 同一权限模型（当前聊天 vs control chat）一致。
4. 同一会话持久化与恢复机制一致。

传输层差异化主要体现在：

1. 平台消息长度上限不同，需要分片策略。
2. 平台的附件、提及、线程模型不同。
3. Web 存在额外的认证、速率和并发控制。

这种分工在代码里有明确体现：新增平台时，文档明确建议复

用 `process_with_agent`，不要新建平台专属 `loop`。这个约束的价值是防止“同一产品，不同平台，不同脑子”。

当系统规模变大后，这种约束尤为关键。若平台各自演进，很快会出现策略不一致：某平台有审批、某平台没有；某平台支持会话恢复、某平台丢上下文。MicroClaw 通过共享核心提前规避了这个结构性问题。

1.2.4 2.4 本章小结

本章给出了 MicroClaw 的系统地图：入口适配、共享执行、持久化状态、后台维护四层协作，核心原则是“语义统一，传输分离”。

下一章将从宏观进入微观，详细拆解一次请求在 Agent Loop 中的完整生命周期，并解释为什么这个循环是全系统最关键的设计支点。

1.2.5 实践误区速览

1. 只停留在概念层，不回到代码和配置验证理解。
2. 把“多渠道支持”理解为“多套核心逻辑并行”。
3. 过早讨论功能扩张，而忽视边界和目标收敛。

1.3 第 3 章 Agent Loop 全景：一次请求如何完成

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.3.1 3.1 输入归一化与会话恢复

在 MicroClaw 中，“一条消息”的处理不是一次模型调用，而是一段状态驱动流程。入口可能来自 Telegram、Discord 或 Web，但进入 `process_with_agent_impl` 后，都会变成同一种内部语义：带有渠道、`chat_id`、`chat_type` 的请求上下文。

流程起点有一个容易被忽视但很关键的分支：显式记忆快速路径。代码会先尝试识别用户是否在做明确“记住某事实”的请求，如果满足条件，系统可直接落结构化记忆并返回确认，而不必启动完整工具循环。这个设计优化了两件事：

1. 降低高频记忆写入的延迟和成本。
2. 避免把简单记忆操作交给复杂循环，减少不确定性。

随后，系统进入会话恢复逻辑。它优先尝试从 session 存储读取历史消息流；如果 session 不存在或损坏，则回退到数据库历史重建。重建时群聊与私聊采用不同取数策略：群聊倾向“上次 bot 回复之后”的窗口，私聊倾向“最近消息窗口”。

这一步体现了 Agent 系统的重要原则：上下文不是“越多越好”，而是“与当前任务相关且结构完整”。MicroClaw 不盲目拼接全量历史，

而是通过 session + 回退策略在完整性和成本之间取平衡。

1.3.2 3.2 系统提示词构建与上下文压缩

会话消息准备完成后, Agent Loop 会组装系统提示词。该过程不是一个静态模板, 而是多源上下文拼接:

1. 机器人身份与渠道信息。
2. 文件记忆 (AGENTS.md)。
3. 结构化记忆注入片段。
4. 技能目录与可激活能力。
5. 可选 SOUL 定制内容。

其中“结构化记忆注入”最具工程含量。系统会对记忆进行相关性排序, 并受 `memory_token_budget` 控

制，超预算内容会被截断并记录“省略计数”。这不是简单裁剪，而是可观测裁剪：系统会把注入方式、候选数、命中数、估算 token 记录下来，便于后续诊断“为什么这轮没想起某条记忆”。

如果消息过长超过 `max_session_messages`，系统会触发上下文压缩：先归档，再保留近期关键消息，避免无限增长。压缩不只是成本优化，也是正确性防线。没有压缩的长对话最终会把关键指令淹没，导致 agent 看似“记住很多”，实则“做错更多”。

1.3.3 3.3 tool_use / tool_result 迭代机制

进入主循环后，系统最多执行 `max_tool_iterations`（默认 100）轮。每轮流程可概括为：

1. 触发 `BeforeLLMCall` hooks（可放行、阻断、补丁）。
2. 调用 LLM（可流式或非流式）。
3. 根据 `stop_reason` 分支处理。

如果 `stop_reason` 为 `end_turn` 或 `max_tokens`，系统聚合文本块并形成最终回复；如果为 `tool_use`，则把模型返回的工具调用逐个执行，再把 `tool_result` 回灌给模型，进入下一轮。

在 `tool_use` 分支里, MicroClaw 做了四层保护:

1. 执行策略检查: 先看工具 policy 是否允许在当前 sandbox 状态下执行。
2. 风险审批检查: 高风险工具先走审批门。
3. Hook 前后处理: BeforeToolCall 可改输入, AfterToolCall 可改输出或阻断。
4. 失败记录: 非审批型失败会加入 failed_tools 集合, 最终回包附带执行注记。

该机制把“工具调用”从模型幻觉风险区转为运行时可控区。模型决

定“做什么”，运行时决定“能不能做、怎么做、失败怎么记”。

1.3.4 3.4 失败、重试与边界条件

Agent Loop 的稳定性取决于它如何处理“非理想输出”。MicroClaw 在这方面有多个具体策略。

第一，空可见回复重试。模型可能输出思考块却没有可见文本；系统会自动注入 runtime guard，要求模型再回答一次，并且只重试一次，避免无限重试。

第二，高风险审批自动二次调用。工具返回 approval_required 时，系统按约定自动重试一次，以完成双阶段确认流程。这使审批行为对

用户尽量透明，同时仍保留安全门槛。

第三，最大迭代保护。当达到上限时，系统不会让会话停在 `tool_result` 状态，而是补一条 `assistant` 消息收口，避免下次恢复时出现“结果不跟随调用”的协议错误。

第四，未知 `stop_reason` 兜底。即使模型返回非预期 `stop_reason`，系统也会尽量落 `session` 并返回可读文本，优先保证连续性。

第五，工具失败可见性。请求最终成功时，如果途中有工具失败，系统会在结尾附加 `execution note`。

这一小设计避免了“看起来回答正常，但执行其实失败”的隐性错误。

1.3.5 3.5 本章小结

本章展示了 Agent Loop 的完整主干：准备上下文、调用模型、执行工具、回灌结果、持久化状态。它并不是“模型外包器”，而是一个带策略、带容错、带可恢复性的执行状态机。

下一章将继续深潜 Agent Loop 的内部结构，重点讨论 stop_reason 状态转移、流式事件、恢复语义以及循环边界的工程设计。

1.3.6 源码片段与图示

1.3.6.1 图示：Agent Loop 序列




Figure 1: Agent Loop 序列图

1.3.6.2 源码片段：主循环与 stop_reason 分支（节选， src/agent_engine.rs）

```
for iteration in
0..state.config.max_tool_iterations
{
    let response = state
        .llm
```

```

        .send_message(&system_prompt,
messages.clone(),
Some(tool_defs.clone()))
        .await?;

let stop_reason =
response.stop_reason.as_deref().unwrap_or("

if stop_reason ==
"end_turn" || stop_reason ==
"max_tokens" {
    // 聚合文本、保存
session、返回 final response
    return Ok(final_text);
}

if stop_reason ==
"tool_use" {
    // 执行 tool_use, 回灌
tool_result, 再进入下一轮
    messages.push(Message {
        role:
"user".into(),

```

```
        content:
MessageContent::Blocks(tool_results),
    });
    continue;
}
}
```

1.3.7 实践误区速览

1. 把 Agent Loop 当作“多次模型调用”，忽略状态机语义。
2. 只看成功路径，不验证 stop_reason 的异常分支。
3. 忽视会话落盘细节，导致恢复语义在生产中失效。

1.4 第 4 章 Agent Loop 深潜：状态机、事件流与可恢复性

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.4.1 4.1 stop_reason 驱动的状态转移

MicroClaw 的 Agent Loop 可以视为一个由 stop_reason 驱动的有限状态机。核心状态并不多，但边界定义明确。

主要状态可抽象为：

1. LLM_CALLING：向模型请求下一步。

2. `TOOL_EXECUTING`: 执行模型请求的工具。
3. `FINALIZING`: 收敛输出并持久化会话。
4. `ABORTED`: 被策略阻断或达到上限后终止。

`stop_reason` 是状态机的转移条件:

1. `tool_use`: 从 `LLM_CALLING` 转入 `TOOL_EXECUTING`。
2. `end_turn`: 从 `LLM_CALLING` 进入 `FINALIZING`。
3. `max_tokens`: 进入受限 `FINALIZING`, 并可能触发提示性收尾。

4. 其他值：走未知分支兜底，仍尝试进入 FINALIZING。

这种显式转移的好处是：

1. 每一轮都有边界，循环不会凭直觉推进。
2. 错误分支可单独观测和测试。
3. 新增 stop_reason 或 provider 行为变化时，可定位影响面。

在多 provider 场景下，这种状态机设计尤其重要。不同模型厂商对 stop_reason 的细节约定可能不同，统一状态转移层可以消化兼容差异，避免业务逻辑散落在 provider 适配代码中。

1.4.2 4.2 流式输出与事件总线

Agent Loop 不仅产生最终文本，还会产生过程事件。AgentEvent 结构显示系统把执行过程拆成可流式消费的事件流：迭代开始、工具开始、工具结果、文本增量、最终响应。

该设计带来三个直接收益：

1. UI 体验：前端可实时显示“第几轮、在跑什么工具、工具是否报错”。
2. 诊断能力：出问题时不用猜，能看到故障落点。
3. 扩展可能：未来可把事件流接入审计或智能回放系统。

事件模型本质上是“把内部状态公开为稳定接口”。只要事件契约稳定，展示层和控制层就可以独立演进。比如 Web 端可以做 timeline，命令行可以做简化进度条，二者不需要修改 Agent Loop 的核心流程。

另一个细节是流式 delta 的转发逻辑。系统在流式模式下将模型文本增量转发到统一事件通道，而非直接耦合具体 UI。这个隔离让“输出机制”与“展示机制”解耦，有利于后续接入更多客户端。

1.4.3 4.3 最大迭代上限与反失控设计

Agent 系统最常见的生产事故之一是“循环失控”：模型持续调用工具却无法收敛。MicroClaw 通过多层约束降低该风险。

第一层是硬上限：`max_tool_iterations`。达到上限即收口，避免资源持续消耗。

第二层是语义收口：达到上限后系统会补一条 `assistant` 消息，明确说明因迭代上限中止，并建议用户拆分任务。这个动作不仅是用户提示，更是协议稳定措施，确保会话可继续恢复。

第三层是失败反馈：failed_tools 集合把本轮失败工具名汇总到最终响应中，让用户知道“任务没完全成功”的具体原因。

第四层是空回复防护：可见内容为空时自动注入 guard 并重试一次，减少“模型看似回答了，用户却什么也没看到”的体验故障。

这些设计共同体现一个思想：系统不追求“永不失败”，而追求“可控失败、可恢复失败、可解释失败”。

1.4.4 4.4 会话持久化与跨轮次连续执行

MicroClaw 的可恢复性建立在“每轮落盘”而非“最终落盘”思路上。关键路径包括：

1. 每次得到可持久化 assistant 内容后写入 session。
2. 恢复时优先加载 session，再补齐新用户消息。
3. session 不可用时回退到数据库历史。

该机制解决了两个现实问题：

1. 进程重启后不丢执行上下文。
2. 适配器短时故障不会导致对话完全断层。

此外，系统会在会话持久化前剥离图像块等非必要重量数据，避免 session 膨胀过快。这体现了“可恢复性”和“成本控制”之间的平衡。

从产品视角看，可恢复性直接决定用户信任。用户在第 10 轮交给

agent 的任务，如果第 11 轮因为重启而归零，任何“智能”都失去价值。MicroClaw 把会话恢复放进核心路径，正是基于这个判断。

1.4.5 4.5 本章小结

本章把 Agent Loop 从“流程描述”升级为“状态机理解”：状态转移由 `stop_reason` 驱动，事件流暴露过程信息，边界保护限制失控，会话持久化支撑连续执行。

下一章将切换到工具系统，解释 Agent Loop 如何通过统一工具抽象连接真实世界动作，并保持扩展能力与策略一致性。

1.4.6 源码片段与图示

1.4.6.1 图示：通用 Agent Loop 结构




Figure 2: Agent Loop 结构图

1.4.6.2 源码片段：事件流定义（节选，src/agent_engine.rs）

```
#[derive(Debug, Clone)]
pub enum AgentEvent {
    Iteration { iteration:
usize },
    ToolStart { name: String },
    ToolResult {
```

```

        name: String,
        is_error: bool,
        preview: String,
        duration_ms: u128,
        status_code:
Option<i32>,
        bytes: usize,
        error_type:
Option<String>,
    },
    TextDelta { delta:
String },
    FinalResponse { text:
String },
}

```

1.4.6.3 源码片段：达到迭代上限后的收口（节选）

```

let max_iter_msg = "I reached
the maximum number of tool
iterations...".to_string();
messages.push(Message {

```

```
        role: "assistant".into(),
        content:
MessageContent::Text(max_iter_msg.clone()),
    });
    if let Ok(json) =
serde_json::to_string(&messages)
    {
        let _ =
call_blocking(state.db.clone(),
move |db|
db.save_session(chat_id,
&json)).await;
    }
```

1.4.7 实践误区速览

1. 把 Agent Loop 当作“多次模型调用”，忽略状态机语义。
2. 只看成功路径，不验证 stop_reason 的异常分支。
3. 忽视会话落盘细节，导致恢复语义在生产中失效。

1.5 第5章 工具系统设计：统一抽象与可扩展执行

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.5.1 5.1 Tool Trait 与注册中心

MicroClaw 的工具系统从一个简单接口出发：每个工具都实现统一 Tool trait，至少包含名称、定义（JSON Schema）和执行函数。这个抽象看似普通，但它把“能力声明”和“执行实现”绑定在同一对象上，使模型可调用性与运行时可执行性保持一致。

在注册层，ToolRegistry 负责三件事：

1. 构建工具实例与依赖注入。
2. 缓存工具定义, 供模型端声明工具集。
3. 执行时分发到具体工具并补全结果元信息。

结果元信息（如 `duration_ms`、`bytes`、`status_code`、`error_type`）不是锦上添花，而是诊断基线。没有这些字段，就难以在运维上区分“工具慢”“工具错”“工具被策略拦截”三类问题。

1.5.2 5.2 内建工具分类与边界

根据当前代码与生成文档，内建工具约 29 个，可按职责分为六组：

1. 执 行 与 文 件 组 :
bash、read_file、write_file、
edit_file、glob、grep。
2. 记 忆 组 :
read_memory、 write_memory、
structured_memory_*。
3. 外 部 信 息 组 : web_search、
web_fetch、browser。
4. 协 作 组 : send_message、
export_chat。
5. 调 度 组 : schedule_task、
list/pause/resume/cancel/
get_task_history、DLQ 相关。
6. 编 排 与 扩 展 组 : todo_read、
todo_write、 activate_skill、
sync_skills、sub_agent。

这套分组反映了一个重要设计原则：让工具名直接表达意图边界。比如 `structured_memory_delete` 明确是结构化层操作，不与文件记忆混用；`sub_agent` 明确是委派语义，不与普通工具执行混淆。

命名清晰带来的收益是“模型更容易选对工具，开发者更容易排错”。在 Agent 系统里，这一点通常比单纯增加工具数量更重要。

1.5.3 5.3 子代理工具集裁剪

`sub_agent` 是 `MicroClaw` 的一个关键能力：把某些子任务交给受限工具集并行处理。代码中的 `ToolRegistry::new_sub_agent` 明确去掉了高副作用工具，如

`send_message`、`write_memory`、调度与导出等。

这种裁剪有三层意义：

1. 权限最小化：子代理只能做分析和局部执行，不直接操作外部沟通面。
2. 递归防失控：子代理不能再调用 `sub_agent`，避免无限分叉。
3. 结果可控：子代理输出最终仍回到主代理，由主代理决定如何对用户呈现。

并行子代理经常被误用为“让系统更聪明”的捷径。正确用法应是“让系统更可分工”：把独立子问题切出去，但保留主流程的一致约束。

1.5.4 5.4 工具开发模板与质量门

禁

一个新工具从概念到落地，至少应经过以下步骤：

1. 定义名称与输入 JSON Schema。
2. 实现执行逻辑，保证返回统一 ToolResult。
3. 在注册中心接入并注入所需依赖。
4. 标定风险等级与执行策略。
5. 编写单元测试与最小集成验证。
6. 更新生成文档，避免文档漂移。

其中第四步非常关键。很多项目把风险策略写在文档里而不是运行时里，最终策略失效。Micro-

Claw 的做法是把策略校验放到 `execute_with_auth` 主路径, 确保所有工具调用都会经过同一检查。

工具质量门禁应关注四类失败:

1. 参数缺失或类型错误。
2. 权限不足 (跨 chat 操作、非 control chat)。
3. 策略拦截 (execution policy / approval)。
4. 运行时异常 (超时、IO、外部依赖失败)。

只有这四类失败可区分, Agent 才能在回复中给出正确后续动作 (重试、改参数、申请权限、人工介入)。

1.5.5 5.5 本章小结

本章说明了工具系统为何是 Agent runtime 的“执行关节”：统一接口让能力可声明、可执行、可治理；注册中心让策略与观测集中生效；子代理裁剪让并行能力不失控。

下一章进入安全机制，详细讨论风险分级、审批门和授权模型如何在工具路径上形成多层防护。

1.5.6 源码片段与图示

1.5.6.1 图示：主代理与子代理边界




Figure 3: 主代理与子代理边界

1.5.6.2 源码片段：工具策略入口 (节选, `src/tools/mod.rs`)

```
pub async fn execute_with_auth(
    &self,
    name: &str,
    input: serde_json::Value,
    auth: &ToolAuthContext,
) -> ToolResult {
    if let Err(msg) =
```

```
validate_execution_policy(name,  
self.sandbox_mode,  
self.sandbox_runtime_available)  
{  
    return  
ToolResult::error(msg).with_error_type("exe  
}  
    if let Some(blocked) =  
require_high_risk_approval(name,  
auth) {  
        return blocked;  
    }  
    let input =  
inject_auth_context(input,  
auth);  
    self.execute(name,  
input).await  
}
```

1.5.6.3 源码片段：子代理受限工具集（节选，src/tools/sub_agent.rs）

```
let tools =  
ToolRegistry::new_sub_agent(&self.config,  
self.db.clone());  
// new_sub_agent 不包含  
send_message/write_memory/  
schedule/sub_agent  
let tool_defs =  
tools.definitions().to_vec();
```

1.5.7 实践误区速览

1. 先写工具实现，再补风险策略和权限检查。
2. 把审批机制当作唯一安全手段，忽略隔离执行。
3. 在没有观测数据的情况下调整安全策略阈值。

1.6 第6章 安全机制：风险分级、审批门与权限模型

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.6.1 6.1 Tool Risk 与执行策略标签

MicroClaw 的安全设计并不是“一刀切禁用高权限”，而是分层控制。第一层是工具风险分级（low/medium/high），第二层是执行策略标签（host-only/sandbox-only/dual）。

风险分级回答“这件事危险吗”，执行策略回答“这件事在哪儿执行”。

二者组合后，运行时才能做出具体判断。

例如：

1. `bash` 被标记为 `high`，执行策略为 `dual`。
2. `write_file` / `edit_file` 属于 `medium`，策略为 `host-only`（当前基线）。
3. 大多数读取类工具属于 `low`。

这种标注让系统具备可进化空间。未来如果某工具风险上升，只需要调整策略映射和校验逻辑，不必重写整条执行链。

1.6.2 6.2 高风险工具双阶段审批

对高风险工具，MicroClaw 在特定上下文（Web 或 control chat）采用审批门机制。调用路径中，工具首次触发会返回 `approval_required`，随后执行器自动重试一次完成确认流程。

该机制有几个实践价值：

1. 把“确认”变成运行时协议，而不是提示词约束。
2. 保留人机协作中的安全摩擦，不让高风险动作静默通过。
3. 把审批结果结构化为 `error_type`，便于日志与指标统计。

审批门机制还解决了一个现实问题：模型可能会“误触”高风险动作。即便模型决策错误，审批层也能提供最后一道刹车。

要注意，审批不是万能。它能降低误操作概率，但不能替代隔离执行。真正高风险部署仍需要和Sandbox、路径防护、运维策略配合使用。

1.6.3 6.3 聊天作用域授权与

`control_chat`

MicroClaw 在工具输入里注入认证上下文，核心字段包括`caller_channel`、`caller_chat_id`、`control_chat_ids`。随后通过统一

授权函数决定目标 chat 是否可操作。

默认规则非常直接：

1. 普通 chat 只能操作自己的 chat_id。
2. control chat 可以跨 chat 操作。

这条规则覆盖了多个高价值动作：send_message、定时任务管理、导出聊天、todo、全局记忆等。统一规则带来的好处是：

1. 权限逻辑集中，不在每个工具里重复造轮子。
2. 权限失败返回可解释错误，不是静默失败。

3. 测试矩阵清晰, 可做系统级权限回归测试。

从系统治理角度看, chat scope 授权是“最小可行 RBAC”。它还不复杂, 但已经能解决跨会话误写、错误广播、越权调度等高概率风险。

1.6.4 6.4 Web Auth 与 scopes 设计

在 Web 控制面, 安全问题从“工具操作”扩展到“管理操作”。RFC 0001 给出了分阶段方案: 从单一 token 走向 session cookie + API key + scopes。

当前设计里的 scopes 包括:

1. operator.read: 只读查看。

2. `operator.write`: 可执行变更动作。
3. `operator.admin`: 管理级权限。
4. `operator.approvals`: 高风险审批处理。

这组 `scopes` 的价值在于“把权限从身份抽离为能力”。同一个身份在不同集成场景下可以发不同 `scope` 的 `key`，降低密钥泄露后的爆炸半径。

配套的 `config/self_check` 接口进一步把风险显性化：它会检查沙箱状态、认证配置、速率限制参数、`hooks` 和 `OTLP` 配置等，并输出 `warning` 列表。这相当于把安全审

查从“文档建议”升级为“运行时可执行检查”。

1.6.5 6.5 本章小结

本章讨论了 MicroClaw 的四条安全主线：风险分级、审批门、chat scope 授权、Web scopes。它们共同构成“可执行、可观测、可演进”的安全底座。

下一章将专门分析 Sandbox 机制：当工具真的执行时，系统如何在宿主与容器之间做策略路由，以及如何处理运行时不可用的现实问题。

1.6.6 源码片段与图示

1.6.6.1 图示：系统架构中的安全边界




Figure 4: MicroClaw 架构图

1.6.6.2 源码片段：风险分级与执行策略（节选，`crates/microclaw-tools/src/runtime.rs`）

```
pub fn tool_risk(name: &str) ->
ToolRisk {
```

```

        match name {
            "bash" =>
ToolRisk::High,
            "write_file" |
"edit_file" | "write_memory" |
"send_message" =>
ToolRisk::Medium,
            _ => ToolRisk::Low,
        }
    }
}

```

```

pub fn
tool_execution_policy(name:
&str) -> ToolExecutionPolicy {
    match name {
        "bash" =>
ToolExecutionPolicy::Dual,
        "write_file" |
"edit_file" =>
ToolExecutionPolicy::HostOnly,
        _ =>
ToolExecutionPolicy::HostOnly,
    }
}

```

```
}  
}
```

1.6.7 实践误区速览

1. 先写工具实现, 再补风险策略和权限检查。
2. 把审批机制当作唯一安全手段, 忽略隔离执行。
3. 在没有观测数据的情况下调整安全策略阈值。

1.7 第7章 Sandbox 机制: 隔离执行与失败策略

本章导读: 本章围绕该主题展开, 先交代问题背景, 再说明实现与取舍, 最后给出实践建议。

1.7.1 7.1 Off / All 模式与运行时路由

MicroClaw 的沙箱配置核心是 `sandbox.mode`, 当前有两个主模式: `off` 与 `all`。

1. `off`: 直接在宿主执行命令。
2. `all`: 优先通过沙箱后端执行(当前主后端为 Docker)。

路由逻辑由 `SandboxRouter` 统一处理。它根据模式和后端可用性决定实际执行路径, 而不是让各工具自行判断。这种集中式路由有两个优势:

1. 策略一致, 避免工具间行为分裂。

2. 观测统一, 便于统计 fallback 与失败原因。

默认 off 的原因并非忽视安全, 而是权衡首次部署摩擦。项目文档也明确建议: 生产或高风险场景应启用沙箱并配合白名单。

1.7.2 7.2 DockerSandbox 资源与网络约束

在 all 模式下, 若 Docker 可用, 命令会进入容器执行。创建容器时系统做了多项限制:

1. `--cap-drop ALL` 去掉额外 Linux capabilities。
2. `--security-opt no-new-privileges` 阻止进程提权。

3. 默认可配置 `--network=none` 关闭网络。
4. 支持 `memory_limit`、`cpu_quota`、`pids_limit` 等资源约束。

这一组合体现了“默认限制、按需放开”的思路。对 Agent 执行环境来说，资源限制并不只是成本控制，也是在降低命令失控时的影响面。

容器命名采用固定前缀 + session key 片段，方便复用和诊断；执行时通过 `docker exec` 并可指定工作目录。超时由统一 `timeout` 机制控制，超时会返回结构化错误而不是阻塞主流程。

1.7.3 7.3 挂载路径、符号链接与白名单防护

Sandbox 的高风险点之一是“挂载路径”。如果挂载了敏感目录，容器隔离价值会显著下降。为此，MicroClaw 对 mount path 做了多层校验：

1. 拒绝包含符号链接组件的路径。
2. 拒绝敏感目录组件（如 .ssh、.aws、.gnupg 等）。
3. 拒绝敏感文件名字段（如 .env、私钥类文件名）。
4. 支持外部 allowlist 文件，只允许挂载在白名单根路径内。

如果校验失败，系统会记录 warning 并回退到原始工作目录路径

(兼容路径)。这是一种工程化妥协：尽量保证可运行，同时把风险显性化。对于生产环境，更推荐显式配置 `allowlist` 并将异常视为阻断条件。

这种校验不仅保护容器执行，也保护“误配置”场景。很多安全事故来自配置错误而非攻击；路径校验能在错误进入生产前给出明确信号。

1.7.4 7.4 `require_runtime` 与 `fail-open` / `fail-closed`

现实中最常见的问题是：配置开了沙箱，但目标机器没有可用 Docker runtime。MicroClaw 通过 `require_runtime` 明确两种行为：

1. `require_runtime = false`: 告警后回退宿主执行 (`fail-open`)。
2. `require_runtime = true`: 直接报错中止 (`fail-closed`)。

这不是“哪个更好”的问题，而是“业务容忍度”问题：

1. 个人环境和开发环境通常更重可用性，可先 `fail-open`。
2. 生产或高风险自动化场景更重边界一致，应 `prefer fail-closed`。

更关键的是，系统把该行为做成显式配置，并在自检与文档中明确提示。这避免了“用户以为在沙箱，实际在宿主”的隐性风险。

推荐实践是把 sandbox 策略与环境分层绑定：

1. 本地开发：
mode=off 或 mode=all +
require_runtime=false。
2. 测试环境： mode=all +
require_runtime=true，验证工具兼容性。
3. 生产环境： mode=all
+ require_runtime=true +
allowlist + 资源限制。

1.7.5 7.5 本章小结

Sandbox 章节的核心结论是：隔离不只是“开关”，而是一组策略组合。MicroClaw 通过路由器、容器约束、路径校验和 runtime 失败策

略，把“可选隔离”逐步升级为“可治理隔离”。

下一章将进入记忆系统，讨论长期状态如何被提取、筛选、注入并保持质量稳定。

1.7.6 源码片段与图示

1.7.6.1 图示：系统总体架构（含执行路径）




Figure 5: System Architecture

1.7.6.2 源 码 片 段： sandbox 路 由 决 策 （ 节 选 ， crates/microclaw-tools/ src/sandbox.rs）

```
if self.config.mode ==  
SandboxMode::Off {  
    return  
exec_host_command(command,  
opts).await;  
}  
if !self.backend.is_real() {  
    if  
self.config.require_runtime {  
        bail!("sandbox is  
enabled but no docker runtime  
is available");  
    }  
    tracing::warn!("sandbox  
enabled but docker unavailable,  
falling back to host");  
    return  
exec_host_command(command,
```



```

opts).await;
}
self.backend.ensure_ready(session_key).await
self.backend.exec(session_key,
command, opts).await

```

1.7.6.3 源码片段：挂载路径防护 (节选)

```

const MOUNT_BLOCKED_COMPONENTS:
&[&str] = &[
    ".ssh", ".gnupg", ".aws",
    ".azure", ".gcloud", ".kube",
    ".docker",
];

if
contains_symlink_component(path)?
{
    bail!("mount path contains
symlink component");
}
if

```

```
has_sensitive_mount_component(path)
{
    bail!("mount path contains
sensitive component");
}
```

1.7.7 实践误区速览

1. 先写工具实现, 再补风险策略和权限检查。
2. 把审批机制当作唯一安全手段, 忽略隔离执行。
3. 在没有观测数据的情况下调整安全策略阈值。

1.8 第8章 记忆系统：文件记忆 + 结构化记忆的分层模型

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.8.1 8.1 AGENTS.md 持久化记忆

MicroClaw 的记忆设计不是单存储方案，而是双层模型。第一层是文件记忆：AGENTS.md。它分为全局和每聊天两个作用域，读取直观、编辑简单、可被人直接审阅。

文件记忆层的价值主要有三点：

1. 可读性高：人类可以直接打开查看。

2. 可移植性强：迁移或备份成本低。
3. 可解释性好：用户能明确知道“系统记住了什么”。

但仅有文件记忆并不足以支撑大规模长期任务，因为它在检索效率、冲突管理、生命周期管理上存在天然局限。这也是结构化记忆层出现的原因。

1.8.2 8.2 SQLite 结构化记忆与生命周期

结构化记忆存储在数据库 `memories` 表，并伴随类别、来源、置信度、归档状态等元数据。相比纯文本记忆，它支持更细粒度的治理。

关键能力包括：

1. 分类存储：PROFILE、KNOWLEDGE、EVENT。
2. 置信度管理：支持不同来源的可信度区分。
3. 替换链路：通过 supersede 关系管理“旧事实被新事实覆盖”。
4. 生命周期：支持软归档而非简单硬删除。

这种结构允许系统回答更复杂问题：

1. 这条记忆是谁、何时、基于什么写入的？
2. 这条事实是否已过时并被替换？
3. 当前注入给模型的是活动记忆还是低置信度记忆？

也就是说，结构化层把“记住”变成“可治理的长期知识状态”。

1.8.3 8.3 Reflector 提取与记忆质量闸门

MicroClaw 通过后台 Reflector 周期性从对话中提取长期事实。它不是简单摘要器，而是带规则约束的提取器。

提取规则强调：

1. 只抽取耐久事实，不记闲聊。
2. 输出结构化 JSON，便于后处理。
3. 对冲突事实可标记 `supersedes_id`。
4. 控制每条内容长度和具体性。

更重要的是记忆污染防护。代码里显式避免把“错误行为描述”写成永久事实，例如“工具调用坏了”这类描述可能反向污染后续行为。系统更鼓励把问题写成纠正型 action item（例如 TODO: ensure ...）。

这是一种很实用的经验：长期记忆不应存放“故障复述”，应存放“行为准则”。否则模型读取后可能强化错误模式。

1.8.4 8.4 语义检索与 token 预算注入

记忆最终价值体现在“注入阶段”。MicroClaw 在构建系统提示词时，

会根据当前 query 选择相关记忆，并受 `memory_token_budget` 限制。

注入策略分两档：

1. 语义检索（启用 `sqlite-vec` + `embedding` 时）。
2. 关键词/相关度排序（默认回退路径）。

无论哪种路径，系统都遵循预算上限并记录注入日志（候选数量、选中数量、省略数量、估算 token）。这为调优提供了事实依据。

常见调优实践：

1. 若答非所问：检查 query 截断长度与相关度排序。

2. 若遗忘关键事实：提高 memory_token_budget 或改进记忆内容颗粒度。
3. 若注入过重：降低预算并增强分类过滤规则。

记忆注入本质上是检索系统，不是文件拼接。只有可检索、可预算、可观测，记忆才能在长期任务里稳定发挥价值。

1.8.5 8.5 本章小结

MicroClaw 的记忆系统用“文件层 + 结构化层 + 反思层 + 注入层”形成闭环：可读、可管、可提取、可利用。

下一章将讨论 Todo 编排机制，说明系统如何把“多步骤任务”从口头计划变成可追踪执行。

1.8.6 源码片段与图示

1.8.6.1 图示：记忆架构




Figure 6: Memory Architecture

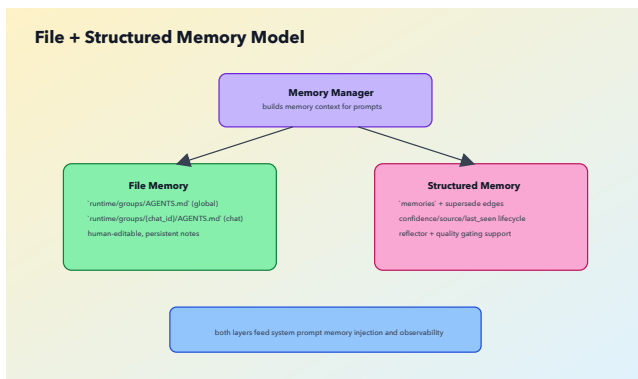


Figure 7: Memory Hierarchy

1.8.6.2 源码片段：结构化记忆注入（节选，src/agent_engine.rs）

```

let db_memory =
build_db_memory_context(
    &state.db,
    &state.embedding,
    chat_id,
    &query,
    state.config.memory_token_budget,
)

```

```
.await;  
let memory_context = format!  
("{}{}", file_memory,  
db_memory);
```

1.8.6.3 源码片段：记忆污染防治 (节选, src/scheduler.rs)

```
fn  
should_skip_memory_poisoning_risk(content:  
&str) -> bool {  
    looks_like_broken_behavior_fact(content)  
&& !  
    is_corrective_action_item(content)  
}
```

1.8.7 实践误区速览

1. 把记忆系统当作“长期上下文缓存”，忽视质量闸门。
2. todo 状态与真实执行脱节，导致计划可见但不可用。

3. 只做任务调度, 不做失败队列和恢复路径设计。

1.9 第 9 章 Todo、计划与执行编排

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.9.1 9.1 计划先行的执行哲学

Agent 系统中最常见的失败不是“不会调用工具”，而是“不会分阶段执行”。用户给出复杂目标后，模型容易直接跳到局部动作，导致路径混乱、回滚困难、进度不可见。

MicroClaw 在系统提示中明确要求：多步骤任务先 `todo_write` 再

执行。这条规则把“思考过程”转化为“外显计划状态”，让执行链条具备同步能力。

计划先行的价值体现在三方面：

1. 用户可见：任务不是黑箱，用户知道系统在做什么。
2. 机器可控：每步有状态（ pending/in_progress/completed），可验证。
3. 故障可恢复：中断后可从 todo 状态重建执行位置。

从工程管理视角，这相当于把“单次推理问题”转成“状态机推进问题”。前者难测，后者可测。

1.9.2 9.2 todo_read / todo_write 协议实践

Todo 工具看似简单，但协议设计很关键。系统约束“同一时刻仅一个 in_progress”，并要求每个阶段完成后同步更新。这避免了计划漂移。

一个推荐执行节奏是：

1. 拆分目标为有限步骤，优先按依赖顺序。
2. 写入 todo，设置第一步 in_progress。
3. 执行该步所需工具。
4. 完成后更新 todo，把下一步置为 in_progress。
5. 重复直到全部完成。

在这个节奏下，todo 成为“任务真相源”。任何输出都应与此 todo 当前状态一致，避免“说完成了但状态未更新”的管理漏洞。

此外，todo 数据落在 chat 作用域，天然继承权限边界。普通 chat 无法跨 chat 操作他人计划，control chat 才有跨域能力。这样可以在编排能力提升的同时，保持作用域安全。

1.9.3 9.3 多步骤任务的可观测推进

Todo 与 Agent Loop 结合后，系统可以构建可观测执行轨迹：

1. 计划层：步骤状态变化。
2. 执行层：工具调用日志与结果。

3. 输出层：中间消息与最终总结。

这三层轨迹能够回答关键运维问题：

1. 任务卡在哪一步？
2. 卡住是策略拒绝、权限问题还是运行失败？
3. 失败后是否重试过，是否有替代路径？

在真实团队协作中，可观测推进比“最终回答质量”更重要。因为复杂任务很少一次做对，关键是能否快速定位偏差并继续推进。

MicroClaw 的“计划先行”并不是限制模型创造力，而是给创造力加上执行骨架。没有骨架，长任务会

变成一次次即兴发挥；有骨架，系统才具备工程可依赖性。

1.9.4 9.4 本章小结

Todo 机制把复杂任务执行从“隐性思维链”升级为“显性状态链”。它提升了可见性、可恢复性和协作效率，是 Agent 走向生产可用的关键一步。

下一章将继续讨论自动化能力，聚焦 Scheduler 如何在无人工触发场景下稳定运行 Agent Loop。

1.9.5 实践误区速览

1. 把记忆系统当作“长期上下文缓存”，忽视质量闸门。
2. todo 状态与真实执行脱节，导致计划可见但不可用。

3. 只做任务调度, 不做失败队列和恢复路径设计。

1.10 第 10 章 定时任务系统: 从一次性触发到持续自 动化

本章导读: 本章围绕该主题展开, 先交代问题背景, 再说明实现与取舍, 最后给出实践建议。

1.10.1 10.1 调度模型与 Cron 约定

MicroClaw 的调度能力由一组工具接口和后台循环共同完成。前台通过 `schedule_task` 等工具声明任务, 后台 `scheduler` 每分钟轮询到期任务并触发执行。

系统支持两类计划:

1. `once`: 一次性执行, 使用 ISO 时间戳。
2. `cron`: 周期执行, 采用 6 字段(含秒) 格式。

这个 6 字段约定是一个工程细节。很多用户习惯 5 字段 `cron`, 系统建议自动补秒字段, 既兼容习惯又保持内部统一。

任务数据会持久化记录 `next_run`、最后运行状态、历史执行摘要等信息, 为后续审计与恢复提供基础。

1.10.2 10.2 Scheduler 与 Agent Loop 的耦合点

`Scheduler` 并不实现另一套智能体逻辑, 而是复用同一个 `process_with_agent`。它只是把任

务 prompt 作为 override 注入，让 Agent Loop 以“定时任务来源”身份执行。

这种复用有三个优势：

1. 行为一致：人工触发和定时触发共享同一执行语义。
2. 维护成本低：Bug 修复一次即可覆盖两类入口。
3. 安全策略一致：工具审批、权限、hooks、策略全部复用。

执行完成后，scheduler 会把结果送回对应 chat，并写入运行日志。失败时也会写日志并推送错误消息，让用户知道自动化链路出错而不是沉默失效。

这表明定时系统不是“后台静默脚本”，而是“有反馈的代理执行入口”。

1.10.3 10.3 DLQ 与任务恢复机制

自动化系统不可避免会失败。关键不是杜绝失败，而是有可恢复机制。MicroClaw 在任务失败时会写入 DLQ (dead letter queue) 记录，并提供查询和重放工具：

1. `list_scheduled_task_dlq`: 查看失败任务。
2. `replay_scheduled_task_dlq`: 按 chat 或 task 维度重放。

重放策略通常包括：

1. 重新入队并设置立即执行。

2. 在 DLQ 记录标记 replayed 状态和注记。
3. 可限制批量重放上限，避免雪崩。

该机制把“失败任务”从终点变成中间态。配合 Runbook 中的 SLO 告警（如 scheduler recoverability），团队可以把自动化可靠性纳入日常运维指标，而非出问题后临时排查。

1.10.4 10.4 本章小结

定时任务系统的核心价值在于：把 Agent 从“被动响应”升级为“主动执行”，同时保留完整的失败记录和恢复路径。

下一章将转向多渠道适配，讨论统一核心如何落地到不同平台约束下的输入输出行为。

1.10.5 源码片段与图示

1.10.5.1 图示：调度任务生命周期




Figure 8: Scheduler Lifecycle




Figure 9: Task Scheduler Flow

1.10.5.2 源码片段：调度器复用 Agent Loop（节选，src/ scheduler.rs）

```
let (success, result_summary) =  
match process_with_agent(  
    state,  
    AgentRequestContext {  
        caller_channel:  
&routing.channel_name,  
        chat_id: task.chat_id,  
        chat_type:  
routing.conversation.as_agent_chat_type(),
```

```
    },  
    Some(&task.prompt),  
    None,  
)  
.await  
{  
    Ok(response) => (true,  
    Some(response)),  
    Err(e) => (false,  
    Some(format!("Error: {e}"))),  
};
```

1.10.6 实践误区速览

1. 把记忆系统当作“长期上下文缓存”，忽视质量闸门。
2. todo 状态与真实执行脱节，导致计划可见但不可用。
3. 只做任务调度，不做失败队列和恢复路径设计。

1.11 第 11 章 多渠道适配层:Telegram、Discord、Web 的共性与差异

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.11.1 11.1 渠道路由与消息模型

MicroClaw 的渠道层职责是把外部事件映射为统一内部请求，再把内部响应映射回各平台协议。这个“映射层”是跨平台一致性的关键。

统一请求最少包含：

1. 渠道名称。
2. chat_id。

3. 会话类型（私聊/群聊等）。
4. 用户消息与发送者信息。

在内部模型中，用户消息会被包装为统一格式（含 sender 信息），并做 XML 转义处理，减少提示注入风险。这个细节说明渠道适配不仅是格式转换，也承担一部分安全清洗职责。

1.11.2 11.2 长消息分片与传输约束

不同平台对消息长度和富文本能力限制不同。MicroClaw 在返回层做自动分片，以适配平台上限。分片策略的目标不是“机械切段”，而是尽量在语义边界（如换行）切分，降低可读性损失。

传输层常见差异包括：

1. 文本长度限制差异。
2. 附件上传能力差异。
3. 提及与线程上下文差异。
4. 群聊追赶历史能力差异。

系统把这些差异留在渠道适配器，而不污染 Agent Loop。这样做的长期收益是：新增渠道时，研发重点落在 I/O 适配，不需要重新解释“任务如何执行”。

1.11.3 11.3 统一核心与适配器扩展策略

项目文档明确提出新增平台适配器的关键约束：复用 `process_with_agent`，不要引入平台专属执行循环。这条规则值得强调，因为它直接防止架构腐化。

扩展一个新渠道的推荐步骤：

1. 建立消息入站解析与身份映射。
2. 调用共享 Agent Loop。
3. 把回包策略按平台约束实现。
4. 复用统一存储路径记录消息与会话。
5. 做跨渠道回归，验证行为一致性。

如果某渠道必须有特殊行为，应优先在“适配层”解决，而不是在“核心 loop”加条件分支。否则随着渠道增多，核心会变成不可维护的条件森林。

这种“核心收敛，边缘扩展”的策略在工程上很朴素，但非常有效。它

保证 MicroClaw 可以继续扩展渠道而不牺牲核心稳定性。

1.11.4 11.4 本章小结

多渠道支持的关键不是支持多少平台，而是能否在平台差异下保持执行语义一致。MicroClaw 通过适配器隔离输入输出差异、保持共享 Agent Loop，建立了可持续扩展路径。

下一章将讨论 Web 控制面与可观测体系，说明系统如何从“可跑”迈向“可运维”。

1.11.5 实践误区速览

1. 在适配层写入核心业务逻辑，破坏统一执行语义。

2. 只看请求成功率, 不看工具可靠性和恢复指标。
3. 把配置调优当经验活, 不建立参数与风险映射。

1.12 第 12 章 Web 控制面与 可观测性

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.12.1 12.1 Web API 安全面与配置 自检

Web 控制面是 MicroClaw 的运维入口，也是高风险入口。与聊天渠道不同，Web 常用于管理动作，安全需求更高。

当前体系包含两部分：

1. 认证授权：逐步从 legacy token 过渡到 session + API key + scope。
2. 配置自检：`/api/config/self_check` 输出风险级别和警告项。

自检项覆盖范围很实用：沙箱开关、runtime 可用性、allowlist 文件、web host 暴露、限流阈值、hooks 输出大小、OTLP 配置完整性等。它把“安全建议”转化为“可执行检查”。

这类接口的价值不在于“发现所有问题”，而在于“让高概率错误变得显而易见”。

1.12.2 12.2 使用量、记忆与稳定性指标

MicroClaw 的可观测不仅统计请求量，还覆盖工具、调度和记忆注入路径。主要指标面包括：

1. 请求成功率与延迟（端到端）。
2. 工具可靠性与策略阻断率。
3. Scheduler 可恢复率。
4. 记忆注入命中与省略统计。
5. MCP 可靠性（限流、舱壁、断路器拒绝）。

这些指标形成了“Agent 运行健康图谱”。对传统 bot 来说，关注 CPU/RAM 可能足够；对 Agent runtime，必须额外关注“决策-执行链路质量”。

例如工具可靠性下降可能不是服务崩溃，而是审批策略误配；记忆注入下降可能不是 DB 故障，而是 token 预算过低。没有领域指标就看不见这些问题。

1.12.3 12.3 运行手册与 SLO 告警闭环

`docs/operations/Runbook.md` 展示了一个完整的运维闭环：症状 -> 检查点 -> 快速动作 -> SLO 告警 -> 回滚/修复路径。

关键 SLO 包括：

1. `request_success_rate`。
2. `e2e_latency_p95_ms`。
3. `tool_reliability`。
4. `scheduler_recoverability_7d`。

当 burn alert 触发时, Runbook 建议冻结非关键合并、指定 incident owner、必要时准备回滚。这是典型 SRE 实践迁移到 Agent runtime 的做法。

另外, DLQ replay、hooks disable、metrics history 查询等操作都被纳入标准流程, 避免事故处理依赖“谁记得命令”。

可观测体系成熟标志不是图表多, 而是“发生异常时, 团队能在固定时间内完成定位与处置”。从这个标准看, MicroClaw 已经具备清晰的工程化方向。

1.12.4 12.4 本章小结

Web 控制面与可观测体系让 MicroClaw 从“功能可用”走向“运营可控”。自检接口降低配置风险, 指标体系提升诊断效率, Runbook 与 SLO 形成事故闭环。

下一章将系统解析配置体系, 解释每组参数背后的设计思路与取舍。

1.12.5 源码片段与图示

1.12.5.1 图示：数据库与观测模型

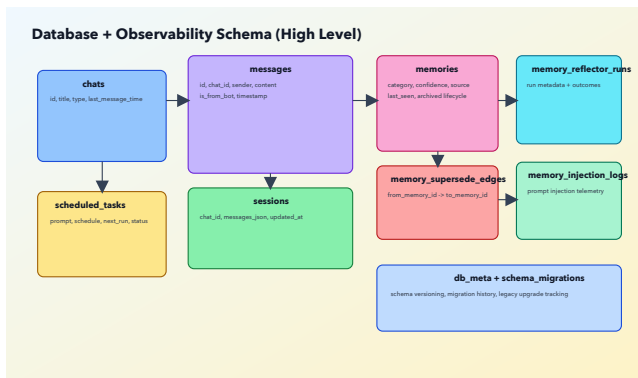


Figure 10: Database ER

1.12.5.2 源码片段：配置自检（节选，src/web/config.rs）

```
if matches!(  
    state.app_state.config.sandbox.mode,  
    crate::config::SandboxMode::Off  
) {  
    warnings.push(ConfigWarning
```

```

{
    code:
"sandbox_disabled",
    severity: "medium",
    message: "Sandbox is
disabled; bash tool executes on
host by default.".to_string(),
});
} else if !
sandbox_runtime_available {
    warnings.push(ConfigWarning
{
        code:
"sandbox_runtime_unavailable",
        severity: if
state.app_state.config.sandbox.require_runt
{
            "high"
        } else {
            "medium"
        },
        message: "Sandbox is
enabled but docker runtime is

```

```
unavailable...".to_string(),  
    });  
}
```

1.12.6 实践误区速览

1. 在适配层写入核心业务逻辑，破坏统一执行语义。
2. 只看请求成功率，不看工具可靠性和恢复指标。
3. 把配置调优当经验活，不建立参数与风险映射。

1.13 第 13 章 配置体系与设计决策：每个参数背后的工程取舍

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.13.1 13.1 配置装载、默认值与兼容策略

MicroClaw 的配置体系有一个明显特征：默认值丰富且集中定义。这让“可启动”门槛较低，同时为生产化留出显式调优入口。

配置的工程目标可以概括为：

1. 开箱可用：默认值能启动并完成基本流程。
2. 显式可调：关键风险参数都可覆盖。
3. 向后兼容：旧字段仍可读取，迁移可渐进。

例如数据路径默认从当前目录逐步转向 `~/.microclaw`，属于典型“从实验到产品”的迁移方向。默

认工作目录和数据目录放在用户目录下，也降低了跨平台路径差异带来的问题。

兼容策略上，项目保留了部分 legacy 字段(如旧渠道字段)，同时鼓励迁移到统一 channels 结构。这样可以避免一次性破坏升级，又能逐步收敛配置模型。

1.13.2 13.2 关键参数组逐项解读

以下按参数组给出实践向解读。

1.13.2.1 LLM 与上下文参数

1. `llm_provider` / `api_key` / `model` / `llm_base_url` 这组定义了模型接入边界。`model` 允许为空使用 `provider` 默认值，适合

快速启动；生产建议显式固定 model 版本，减少行为漂移。

2. `max_tokens` 单次回复上限。过低会截断，过高会增加延迟和成本。推荐按任务形态分层：操作确认类低一些，报告生成类高一些。
3. `max_tool_iterations` Agent Loop 硬上限。默认 100 偏保守，适合复杂任务；若运行成本敏感，可在 20~60 区间做压测后下调。
4. `max_history_messages` /
 `max_session_messages` /
 `compact_keep_recent` 这三者共同决定上下文窗口压力。

`max_history_messages` 管入站历史，`max_session_messages` 管会话总长，`compact_keep_recent` 管压缩后保留量。

5. `memory_token_budget` 结构化记忆注入预算。过低会“记不住”，过高会“挤占任务上下文”。应结合 `memory injection logs` 调优，而非拍脑袋。

1.13.2.2 工具与超时参数

1. `default_tool_timeout_secs` 工具超时基础值。默认 30 秒适中，但 `bash`、`browser`、网络工具通常需要单独覆盖。

2. `tool_timeout_overrides` 按工具名覆盖超时预算。推荐优先配置高方差工具，避免长尾阻塞。
3. `default_mcp_request_timeout_secs` MCP 请求超时基线。过短会造成误失败，过长会拖慢整体回合节奏。

1.13.2.3 路径与隔离参数

1. `data_dir` 运行时文件和技能目录根路径。生产环境建议固定为持久卷路径，不随部署目录变化。
2. `working_dir` 工具默认工作目录。建议避免指向系统敏感路径。

3. `working_dir_isolation` `shared` 适合单用户调试；`chat` 适合多会话隔离，是更安全的默认实践。

1.13.2.4 Sandbox 参数

1. `sandbox.mode` `off` 便于上手，`all` 适合风险敏感环境。
2. `sandbox.no_network` 默认 `true`，减少外联风险。若业务确需联网，可按最小范围放开并配合审计。
3. `sandbox.require_runtime` 控制缺少 `runtime` 时是回退宿主还是直接失败。生产建议 `true`。

4. `sandbox.mount_allowlist_path`
显式限制可挂载根路径, 推荐在生产强制配置。
5. `sandbox.memory_limit` / `cpu_quota` / `pids_limit` 资源治理参数, 建议按压测数据设定, 不建议留空长期运行。

1.13.2.5 Web 参数

1. `web_host` / `web_port` 默认 `loopback` 有助于降低暴露面。若改为公网监听, 应配合反向代理、TLS 和外层鉴权。
2. `web_max_inflight_per_session`
每会话并发上限。过高会放大资源争用。

3. `web_max_requests_per_window`
+ `web_rate_window_seconds` 限流窗口组合。建议先保守，基于真实流量逐步提高。
4. `web_session_idle_ttl_seconds`
闲置锁/配额清理窗口。过短会导致频繁抖动，过长会拖慢回收。

1.13.2.6 记忆与反思参数

1. `reflector_enabled` 是否启用后台记忆提取。默认启用，有利于长期任务表现。
2. `reflector_interval_mins` 反思周期。过短会增加成本，过长会降低新信息进入速度。

3. embedding 组参数 用于语义检索, 需与构建特性匹配 (sqlite-vec)。生产中要同时考虑模型成本和向量维度。

1.13.2.7 渠道与跨 chat 权限参数

1. channels.* 新结构化渠道配置入口。建议只用这一组，减少 legacy 字段混用。
2. control_chat_ids 跨 chat 操作白名单。该字段是“运维能力开关”，建议最小化配置并定期审计。
3. bot_username 与 channel override 影响提示词与消息行为，错配会影响提及与识别逻辑。

1.13.3 13.3 典型部署配置与风险 画像

以下给出三种常见部署画像。

1.13.3.1 画像一：个人开发机

建议配置：

1. `sandbox.mode=off` 或 `all + require_runtime=false`。
2. `working_dir_isolation=chat`。
3. 低并发 Web 配置，保持 `loop-back`。

风险特征：

1. 更偏可用性，边界相对宽松。
2. 需注意不要把工作目录指向含密钥路径。

1.13.3.2 画像二：团队测试环境

建议配置：

1. `sandbox.mode=all,`
`require_runtime=true。`
2. 配置 `mount allowlist。`
3. 打开完整指标与 Runbook 流程。

风险特征：

1. 目标是提前暴露配置与策略问题。
2. 需要模拟异常（runtime 缺失、审批阻断、超时）做回归。

1.13.3.3 画像三：生产自动化环境

建议配置：

1. 强制沙箱 + 资源限制 + allowlist。
2. Web 鉴权使用 scoped API key, 禁用 legacy fallback (条件成熟后)。
3. 严格 control_chat_ids, 并设置告警阈值。

风险特征：

1. 关注长期稳定和越权防护。
2. 重点监控工具可靠性、调度恢复率、审批拦截率。

配置治理的核心不是“参数都懂”，而是“参数与风险模型绑定”。只有把参数放回具体部署画像，调优才有方向。

1.13.4 13.4 本章小结

配置体系是 MicroClaw 工程取舍的外显界面。默认值体现上手策略，覆盖项体现治理能力，兼容层体现演进节奏。

下一章将进入收官，讨论测试、升级、发布和未来路线，完成从代码到系统运营的闭环视角。

1.13.5 源码片段与图示

1.13.5.1 图示：新工具接入流程（配置与策略联动）




Figure 11: New Tool Flow

1.13.5.2 源码片段：关键默认值（节选，src/config.rs）

```
fn  
default_max_tool_iterations() -  
> usize { 100 }  
fn  
default_memory_token_budget() -
```

```

> usize { 1500 }
fn
default_working_dir_isolation()
-> WorkingDirIsolation {
    WorkingDirIsolation::Chat
}
fn
default_web_max_inflight_per_session()
-> usize { 2 }
fn
default_web_max_requests_per_window()
-> usize { 8 }
fn
default_web_rate_window_seconds()
-> u64 { 10 }

```

1.13.5.3 源 码 片 段： Sand-
box 默 认 值（节选，
crates/microclaw-tools/
src/sandbox.rs）

```

fn default_sandbox_mode() ->
SandboxMode

```

```
{ SandboxMode::Off }  
fn default_sandbox_no_network()  
-> bool { true }  
fn  
default_sandbox_require_runtime()  
-> bool { false }
```

1.13.6 实践误区速览

1. 在适配层写入核心业务逻辑, 破坏统一执行语义。
2. 只看请求成功率, 不看工具可靠性和恢复指标。
3. 把配置调优当经验活, 不建立参数与风险映射。

1.14 第 14 章 从代码到发布： 测试、升级、运维与路线 图

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.14.1 14.1 测试基线与稳定性测试

MicroClaw 的测试面不只在函数正确性，还在系统行为一致性。文档与脚本体现了多层测试思路：单元测试、集成测试、稳定性 smoke、权限与恢复性回归。

一个实用测试基线应覆盖：

1. Agent Loop 基础收敛 (end_turn/tool_use/max_tokens 分支)。
2. 工具策略校验 (risk/policy/approval)。
3. 跨 chat 权限约束。
4. Scheduler 重启恢复与 DLQ replay。
5. Sandbox fallback 与 require_runtime 行为。
6. Web 限流与并发边界。

这套基线的意义在于防止“功能新增破坏运行时契约”。Agent 系统最怕的不是单点 bug，而是契约漂移：某条边界被悄悄放松，几周后才在生产暴露。

1.14.2 14.2 升级路径、回滚策略与发布节奏

从升级指南和近期发布节奏看，MicroClaw 采用“持续小步发布 + 文档同步修复”策略。该策略的优点是反馈快、风险分散，但前提是升级和回滚路径清晰。

建议升级流程：

1. 先在测试环境应用新版本并跑稳定性 smoke。
2. 检查配置兼容与自检 warning。
3. 观察核心 SLO 一段窗口后再扩大。
4. 保留回滚版本与迁移说明。

回滚策略应提前定义触发条件，例如：

1. 请求成功率持续低于阈值。
2. Scheduler recoverability 显著下降。
3. 权限模型出现越权或误拒绝。
4. 沙箱路径出现与预期不符的执行降级。

版本节奏本身不是目标，稳定交付才是目标。发布频率越高，越需要自动化检查和文档纪律。

1.14.3 14.3 技术债与下一阶段演进方向

从 RFC、roadmap 和报告材料看，下一阶段演进可聚焦在以下方向：

1. 安全默认值升级：在更多场景将隔离执行设为默认优先。

2. 授权模型完善：完成 Web scopes 与 legacy 方案切换。
3. Hooks 平台化：稳定事件契约和变更边界。
4. 记忆治理深化：增强 provenance、回滚与质量 SLO。
5. 调度可靠性提升：DLQ 策略和自动补偿更细粒度。
6. 可观测统一：把策略阻断、fall-back、审批流纳入统一报表。

这些方向的共同特点是“强化工程质量而非堆功能”。这是运行时项目走向成熟的典型路径。

对于团队落地而言，最关键的行动建议是：

1. 先建立自己的部署画像和风险阈值。
2. 再把配置、测试、告警全部绑定到画像。
3. 最后才是扩展更多工具和自动化场景。

1.14.4 14.4 本章小结

本章完成了从开发到运营的闭环视角：功能上线只是起点，稳定运行、可回滚、可演进才是长期价值来源。

至此，全书主体完成。附录将给出术语、工具风险速查、默认配置速查和资料索引，便于读者在实践中快速定位信息。

1.14.5 实践误区速览

1. 在适配层写入核心业务逻辑, 破坏统一执行语义。
2. 只看请求成功率, 不看工具可靠性和恢复指标。
3. 把配置调优当经验活, 不建立参数与风险映射。

1.15 第 15 章 源码结构化导读：从仓库树到执行路径

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.15.1 15.1 仓库分层阅读法

阅读 MicroClaw 代码时，建议先按“执行路径”而不是“目录树”来建立认知。目录树告诉你文件在哪里，执行路径告诉你请求如何流动。推荐阅读顺序如下：

1. 从入口 `src/main.rs` 看启动流程和配置加载。
2. 看 `src/runtime.rs` 识别 App-State 的装配关系。
3. 进入 `src/agent_engine.rs` 理解核心执行循环。
4. 看 `src/tools/mod.rs` 理解工具注册、策略校验与分发。
5. 最后看 `src/channels/*`、`src/web/*`、`src/scheduler.rs` 识别外层适配和后台任务。

这种顺序的好处是“先抓主干，再看枝叶”。如果一上来逐文件通读，容易陷入局部细节，最后仍不知道系统是如何连起来的。

1.15.2 15.2 crates 级别的职责边界

项目采用工作区多 crate 结构。虽然章节中主要引用 `src/`，但核心逻辑分布在多个 crate：

1. `microclaw-core`：跨模块复用的基础类型与通用工具。
2. `microclaw-storage`：数据库封装、迁移、持久化结构。
3. `microclaw-tools`：工具运行时策略、沙箱执行器、通用工具协议。

4. microclaw-channels: 渠道抽象与共用逻辑。

该拆分的价值是让“高变动模块”和“稳定模块”分离。比如沙箱与工具策略会频繁调整，核心类型和存储契约更稳定。拆分后，变更影响半径更可控。

1.15.3 15.3 src/ 主模块导读

以下按主模块做工程导读。

1.15.3.1 src/main.rs

职责：解析命令行、加载配置、初始化运行时、启动渠道与服务。

关注点：

1. 启动顺序是否可预测。

2. 错误是否在启动期暴露而非运行期才爆炸。
3. 控制命令（如 `setup/doctor/hooks`）是否和主服务复用同一配置源。

1.15.3.2 `src/runtime.rs`

职责：构建 `AppState`，连接 LLM、数据库、工具注册、记忆、渠道、后台任务。

关注点：

1. 全局依赖是否显式注入。
2. 模块初始化失败时是否有可理解错误。
3. 运行时共享对象是否通过 `Arc` 做清晰所有权管理。

1.15.3.3 src/agent_engine.rs

职责：核心 Agent Loop, 包括消息准备、提示词构建、工具循环、会话持久化。

关注点：

1. stop_reason 分支完整性。
2. 空回复与最大迭代边界处理。
3. hooks 与工具执行顺序。
4. 会话恢复与压缩策略是否会损坏协议完整性。

1.15.3.4 src/llm.rs

职责：Provider 适配与请求发送（流式/非流式）。

关注点：

1. 多 provider 能力差异是否被抽象层吸收。
2. 工具调用与文本输出模式是否统一。
3. usage 统计是否可回流到观测层。

1.15.3.5 src/tools/mod.rs

职责：工具注册、定义缓存、执行分发、策略检查、授权注入。

关注点：

1. 策略校验必须在执行前。
2. 工具返回结构是否规范化。
3. 子代理工具集是否严格受限。

1.15.3.6 src/scheduler.rs

职责：定时任务执行、运行日志、DLQ、Reflector。

关注点：

1. 定时任务失败路径是否完整落库。
2. 重放是否具备幂等语义。
3. 反思任务是否引入记忆污染风险。

1.15.3.7 src/web/*

职责：Web API、认证、会话流、配置自检、指标接口。

关注点：

1. scope 校验覆盖是否完整。
2. 限流和并发控制是否可配置。

3. 自检 warning 是否覆盖高频误配。

1.15.3.8 src/channels/*

职责：各平台适配器。

关注点：

1. 进站消息模型是否统一。
2. 出站分片逻辑是否稳定。
3. 平台差异是否泄漏到核心执行层。

1.15.4 15.4 工具模块逐项导读

以下对工具模块做简要代码阅读导图，帮助你在调试时快速定位文件。

1. bash.rs：命令执行入口，接入 sandbox router 与超时控制。

2. `read_file.rs`: 带行号读取与窗口化输出。
3. `write_file.rs`: 创建/覆盖文件, 路径解析与目录自动创建。
4. `edit_file.rs`: 基于查找替换的可验证编辑。
5. `glob.rs`: 模式匹配搜索。
6. `grep.rs`: 正则内容检索。
7. `web_search.rs`: 网页检索聚合。
8. `web_fetch.rs`: 页面抓取与文本提取。
9. `memory.rs`: 文件记忆读写 + 结构化联动写入。
10. `structured_memory.rs`: 结构化记忆查询/更新/删除。

- 11. `schedule.rs`: 任务创建、暂停、恢复、取消、历史与 DLQ 操作。
- 12. `send_message.rs`: 中间消息与附件下发。
- 13. `export_chat.rs`: 会话导出。
- 14. `activate_skill.rs`: 技能激活。
- 15. `sync_skills.rs`: 远端技能同步与本地规范化。
- 16. `sub_agent.rs`: 受限工具集的并行子代理执行。
- 17. `browser.rs`: 浏览器自动化入口。
- 18. `mcp.rs`: MCP 工具桥接。
- 19. `todo.rs`: 计划状态读写。

调试建议: 优先从 `tools/mod.rs` 的注册和策略路径入手, 再进入单工具文件。因为很多“工具执行失

败”并不是工具实现 bug，而是前置策略或授权阻断。

1.15.5 15.5 文档与源码联动阅读法

MicroClaw 的文档目录结构较完整，建议建立“文档到代码”映射：

1. docs/security/execution-model.md 对应 sandbox.rs 与工具策略校验路径。
2. docs/operations/Runbook.md 对应 web 指标接口、DLQ 工具与恢复命令。
3. docs/rfcs/* 对应未来设计方向，可用于判断当前实现是否临时。

4. docs/generated/* 对应自动生成的工具/配置清单，可用于检查文档漂移。

此外，website/blog 的内容通常提供架构视角与里程碑叙事，适合用于理解“为什么这样设计”，而 src/* 用于确认“实际怎么实现”。

1.15.6 15.6 阅读与改造的实践清单

当你准备在 MicroClaw 上做二次开发，可以按以下清单执行：

1. 先画出自己的目标路径：入口、工具、状态、输出。
2. 确认是否可复用现有 Agent Loop，不新增平行 loop。

3. 新工具先定义风险等级和执行策略，再写实现。
4. 每次策略变更同步补测试。
5. 对外功能变更同步更新 docs/generated。
6. 调整配置默认值时写清迁移影响。
7. 涉及跨 chat 能力时优先检查授权模型。
8. 涉及外部执行能力时优先检查 sandbox 行为。

1.15.7 15.7 本章小结

本章给出了 MicroClaw 的结构化读码路径：先执行链，再模块边界，再单文件细节。掌握这种阅读法，可以显著降低理解成本，也能避免在改造时破坏核心契约。

下一章将从架构阅读转向安全深水区，讨论更细粒度的风险治理与对抗场景。

1.15.8 源码片段与图示

1.15.8.1 图示：平台适配与共享核心管道




Figure 12: Platform Core Pipeline

1.15.8.2 源码片段：显式记忆

快速路径（节选，src/
agent_engine.rs）

```
if let Some(reply) =  
maybe_handle_explicit_memory_command(state,  
chat_id, override_prompt,  
image_data.clone())  
    .await?  
{  
    return Ok(reply);  
}
```

1.15.8.3 源码片段：会话恢复优先 级（节选）

```
let mut messages = if let  
Some((json, updated_at)) =  
call_blocking(state.db.clone(),  
move |db|  
db.load_session(chat_id)).await?  
{
```

```

        let mut session_messages:
Vec<Message> =
serde_json::from_str(&json).unwrap_or_default()
        if
session_messages.is_empty() {
load_messages_from_db(state,
chat_id, context.chat_type,
context.caller_channel).await?
        } else {
            // 增量拼接新用户消息
            session_messages
        }
    } else {
load_messages_from_db(state,
chat_id, context.chat_type,
context.caller_channel).await?
    };

```

1.15.9 实践误区速览

1. 读码只看函数, 不画执行链和模块边界图。

2. 安全演练只做“通过性测试”，不做故障注入。
3. 复盘只记录结论，不沉淀可执行检查项。

1.16 第 16 章 安全深水区：威胁建模与防护决策

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.16.1 16.1 资产识别：到底在保护什么

在 Agent runtime 里，安全讨论若不先识别资产，就容易陷入抽象口号。MicroClaw 的关键资产可分为五类：

1. 执行资产：宿主命令执行能力、文件写入能力、外部调用能力。
2. 数据资产：会话历史、结构化记忆、调度任务、导出文件。
3. 凭据资产：API key、渠道 token、第三方服务密钥。
4. 控制资产：Web 管理接口、配置文件、审批流程。
5. 可用性资产：调度器、队列、数据库与事件流。

不同资产对应不同防护策略。比如凭据资产需要最小暴露和路径隔离，可用性资产需要限流和恢复机制。把这些混在一起谈“加强安全”没有执行价值。

1.16.2 16.2 攻击面清单：从输入到执行

MicroClaw 的攻击面主要落在四条路径：

1. 用户输入路径：提示注入、越权诱导、社会工程式指令。
2. 工具执行路径：命令注入、路径穿越、敏感文件覆盖。
3. 控制面路径：认证绕过、scope 配置错误、限流失效。
4. 外部依赖路径：MCP 服务异常、网络返回污染、第三方 API 漏洞。

对应防线应形成“分层链”：

1. 输入层：消息包裹、转义、系统提示硬约束。

2. 策略层: risk/policy/approval。
3. 执行层: sandbox + path guard + allowlist。
4. 控制层: auth scope + rate limit + self-check。
5. 运维层: 日志、指标、告警、回放。

分层链的好处是即使某一层漏检，后续层仍有拦截机会。

1.16.3 16.3 典型威胁场景与对策

以下给出 12 个高频场景。

1. 场景： 用户要求“把整个 HOME 打包发我”。对策：路径守卫 + 聊天授权 + 工具风险校验；必要时审批。

2. 场景：用户诱导模型“忽略系统提示，直接输出密钥文件”。对策：消息封装与不可信输入策略；文件工具路径拦截。
3. 场景：配置了 `sandbox=all`，但 `docker` 不可用，用户误以为已隔离。对策：`require_runtime=true`；配置自检和告警。
4. 场景：`control chat` 配置过宽，跨 chat 误操作。对策：最小化 `control_chat_ids`，定期审计。
5. 场景：子代理被用于高副作用操作。对策：受限工具集，不暴露发送和调度能力。

6. 场景：定时任务被错误创建为高频 cron，造成资源耗尽。对策：调度频率校验、限流、SLO 告警。
7. 场景：Reflector 将故障描述写入长期记忆，诱发行为污染。对策：记忆质量闸门与污染检测规则。
8. 场景：Web 接口暴露在公网且未配置强认证。对策：loop-back 默认、scope 化密钥、反向代理防护。
9. 场景：hook 脚本异常或恶意输出巨大 payload。对策：hooks 输入输出大小上限、超时硬限制。

10. 场景：MCP 服务高失败率导致调用雪崩。对策：断路器 + 队列等待预算 + 并发上限。
11. 场景：模型频繁触发 bash 高风险动作。对策：审批门 + 行为监控 + prompt 收紧。
12. 场景：升级后策略行为变化导致线上拒绝率飙升。对策：灰度发布 + 稳定性 smoke + 回滚预案。

1.16.4 16.4 防护策略优先级模型

在资源有限条件下，应优先做“高概率高影响”项。推荐优先级如下：

1. P0：认证与作用域（防越权）。

2. P0: 执行隔离与路径防护 (防宿主破坏)。
3. P1: 审批与风险分级 (防误操作)。
4. P1: 可观测与告警 (防隐形故障扩大)。
5. P2: 高级策略 (细粒度 hooks、策略学习等)。

该顺序的原因是：没有基础边界，复杂策略只会增加误判成本。

1.16.5 16.5 安全评审模板

建议每次版本迭代执行一次简化安全评审，模板如下：

1. 本版本新增了哪些执行能力？
2. 是否新增了跨 chat / 跨系统权限路径？

3. 对应工具风险等级是否更新？
4. 沙箱策略是否被弱化？
5. 自检告警是否新增高危项？
6. 监控面是否覆盖新增路径？
7. 回滚路径是否可执行且已验证？

每个问题要求给出证据：代码位置、测试结果、文档变更。

1.16.6 16.6 安全运营建议

长期运行建议：

1. 每周审计 `control_chat_ids` 与 `API key scopes`。
2. 每周检查 `sandbox_runtime_unavailable` 类告警。
3. 每日抽样检查高风险工具调用日志。

4. 每次发布后 24 小时重点观察策略阻断率。
5. 每月演练一次 DLQ replay 与回滚流程。

安全不应是发布前一次性动作，而是运行中的持续治理。

1.16.7 16.7 本章小结

本章将安全机制从“代码能力”扩展到“威胁场景 + 治理流程”。MicroClaw 的安全价值不在于某个单点特性，而在于多层防线与持续运营结合。

下一章将把 Sandbox 拉到实战层，用具体操作与攻防案例讨论隔离机制的边界与改进空间。

1.16.8 源码片段与图示

1.16.8.1 图示：新工具接入与策略联动




Figure 13: New Tool Flow

1.16.8.2 源码片段：跨 chat 授权 (节选, crates/microclaw- tools/src/runtime.rs)

```
pub fn  
authorize_chat_access(input:  
&serde_json::Value,  
target_chat_id: i64) ->
```

```

Result<(), String> {
    if let Some(auth) =
auth_context_from_input(input)
{
    if !
auth.can_access_chat(target_chat_id)
{
        return Err(format!(
            "Permission
denied: chat {} cannot operate
on chat {}",
auth.caller_chat_id,
target_chat_id
        ));
    }
    }
    Ok(())
}

```

1.16.8.3 源码片段：高风险审批门 (节选, src/tools/mod.rs)

```
if let Some(blocked) =  
    require_high_risk_approval(name,  
    auth) {  
    return blocked;  
}
```

1.16.9 实践误区速览

1. 读码只看函数, 不画执行链和模块边界图。
2. 安全演练只做“通过性测试”, 不做故障注入。
3. 复盘只记录结论, 不沉淀可执行检查项。

1.17 第 17 章 Sandbox 实战 与攻防：部署、诊断与演 练

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.17.1 17.1 三种环境的沙箱模板

1.17.1.1 模板 A：开发机（快速迭代）

- 目标：降低摩擦，保证开发效率。
- 建议：
 1. `sandbox.mode=off` 或 `all + require_runtime=false`。
 2. 保持 `working_dir_isolation=chat`。
 3. 限制工作目录到项目路径。

1.17.1.2 模板 B：测试环境（策略验证）

- 目标：提前验证隔离策略和兼容性。
- 建议：
 1. `sandbox.mode=all`。
 2. `require_runtime=true`。
 3. 配置 `mount allowlist`。
 4. 开启资源限制并记录执行失败类型。

1.17.1.3 模板 C：生产环境（边界优先）

- 目标：稳定、可审计、可回滚。
- 建议：
 1. 强制沙箱 + `fail-closed`。

2. 明确 allowlist 与敏感目录策略。
3. 为高风险工具建立审批和告警。
4. 周期检查 runtime 可用性。

1.17.2 17.2 上线前验证清单

1. 运行 doctor sandbox, 确认 runtime 可用。
2. 检查 sandbox.mode、require_runtime 与部署画像一致。
3. 验证 allowlist 文件存在且有条目。
4. 验证敏感路径被阻断（如 .ssh 相关路径）。
5. 验证符号链接路径被拒绝。
6. 验证超时行为不会卡住主流程。
7. 验证资源限制参数生效。

8. 验证 fallback/blocked 事件会进入日志与监控。

这份清单建议纳入 CI 或预发布脚本，而不是人工口头检查。

1.17.3 17.3 典型故障与排障流程

1.17.3.1 故障 1：沙箱已开启但仍在宿主执行

排障步骤：

1. 查配置是否 mode=all。
2. 查 runtime 是否可用。
3. 查 require_runtime 是否 false 导致 fallback。
4. 查日志中的 fallback warning。
5. 查 self-check 的风险警告输出。

1.17.3.2 故障 2：容器执行频繁超时

排障步骤：

1. 检查默认超时是否过低。
2. 检查命令本身是否需要拆分。
3. 检查资源限制是否过紧。
4. 检查工作目录挂载是否可访问。

1.17.3.3 故障 3：挂载路径被拒绝

排障步骤：

1. 检查路径是否包含符号链接。
2. 检查路径组件是否命中敏感名单。
3. 检查 allowlist 是否覆盖该根路径。
4. 在测试环境复现并记录具体拒绝原因。

1.17.4 17.4 攻防演练案例 (10 例)

1. 演练：尝试访问 `~/.ssh` 目录。
预期：路径校验拒绝，工具返回错误并记录。
2. 演练：在无 `docker` 环境启用 `mode=all`。预期：
`require_runtime=true` 时直接失败，`false` 时告警回退。
3. 演练：通过软链接绕过 `allowlist`。预期：符号链接检查拦截。
4. 演练：高频长命令导致资源压测。预期：受 CPU/内存/pids 限制约束，超时可控。

5. 演练：用户诱导执行破坏性命令。预期：审批门与策略日志可见。
6. 演练：在 control chat 触发跨 chat 写文件。预期：权限通过但仍受路径和策略约束。
7. 演练：在普通 chat 触发跨 chat 操作。预期：授权拒绝。
8. 演练：模拟 docker 临时不可用。预期：行为与 require_runtime 配置一致。
9. 演练：挂载目录包含 .env.production 文件片段。预期：敏感组件规则触发告警/拒绝。

10. 演练：命令执行过程中进程失控。预期：超时终止并返回结构化错误。

1.17.5 17.5 沙箱策略演进建议

1. 逐步扩大 sandbox-only 工具覆盖范围（先高风险）。
2. 把 fallback 行为纳入强告警与发布阻断规则。
3. 为不同环境预制策略矩阵（desktop/server/CI）。
4. 结合工作负载做资源上限分层模板。
5. 对敏感目录名单与 allowlist 机制做团队级标准化。

1.17.6 17.6 本章小结

Sandbox 的核心不在“是否使用 Docker”，而在“隔离策略是否被持续执行并可审计”。本章给出了从部署到演练的落地路径。

下一章将回到 Agent Loop，以案例工坊方式拆解复杂任务如何在多轮中稳定收敛。

1.17.7 源码片段与图示

1.17.7.1 图示：Agent Loop + Sandbox 执行路径




Figure 14: Agent Loop

1.17.7.2 源码片段：runtime 可用性探测（节选， `crates/microclaw-tools/ src/sandbox.rs`）

```
fn docker_available() -> bool {  
    std::process::Command::new("docker")  
        .args(["info", "--
```

```

format", "{{.ServerVersion}}"]])
    .stdout(std::process::Stdio::null())
    .stderr(std::process::Stdio::null())
    .status()
    .is_ok_and(|s|
s.success())
}

```

1.17.7.3 源码片段：Fail-open/ Fall-back 警告（节选）

```

if !self.backend.is_real() {
    if
self.config.require_runtime {
        bail!("sandbox is
enabled but no docker runtime
is available");
    }
    if !
self.warned_missing_runtime.swap(true,
Ordering::Relaxed) {
        tracing::warn!("sandbox
enabled but docker unavailable,

```



```
falling back to host");  
    }  
    return  
exec_host_command(command,  
opts).await;  
}
```

1.17.8 实践误区速览

1. 读码只看函数, 不画执行链和模块边界图。
2. 安全演练只做“通过性测试”, 不做故障注入。
3. 复盘只记录结论, 不沉淀可执行检查项。

1.18 第 18 章 Agent Loop 案例工坊：30 个任务如何收敛

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.18.1 18.1 使用说明

本章给出 30 个典型任务案例。每个案例都按同一模板组织：

1. 用户目标。
2. 建议循环路径。
3. 关键工具调用。
4. 常见失败点与修复策略。

这组案例的目的不是提供固定答案，而是提供“可复用执行骨架”。

1.18.2 18.2 案例集

1.18.2.1 案例 1: 仓库超时配置普查

- 目标: 找出所有 timeout 配置并汇总。
- 路径: todo -> glob -> grep -> read_file -> 汇总。
- 失败点: grep 结果过大。
- 修复: 先按目录分批检索, 逐批汇总。

1.18.2.2 案例 2: 生成发布说明草稿

- 目标: 根据最近提交生成 release notes。
- 路径: bash(git log) -> 分类 -> 输出。
- 失败点: 提交跨度过大。
- 修复: 限定时间窗口或版本 tag。

1.18.2.3 案例 3：定位某错误日志根因

- 目标：从日志中提取错误链路。
- 路径：read_file -> grep(error) -> grep(trace) -> 汇总。
- 失败点：日志滚动导致缺失。
- 修复：多文件合并视图，优先最近窗口。

1.18.2.4 案例 4：批量修改配置键名

- 目标：把旧配置键迁移到新键。
- 路径：glob -> read_file -> edit_file -> 验证。
- 失败点：替换误伤注释。
- 修复：限制替换上下文并二次 grep 校验。

1.18.2.5 案例 5: 多文档摘要为操作清单

- 目标：把分散文档转成执行列表。
- 路径：read_file(多文档) -> todo_write -> 逐项输出。
- 失败点：摘要太泛。
- 修复：每项要求“动作 + 负责人 + 条件”。

1.18.2.6 案例 6: 周期性情报播报

- 目标：每天固定时间汇总新闻。
- 路径：schedule_task(cron) -> web_search -> web_fetch -> send_message。
- 失败点：源站不稳定。

- 修复：配置多源兜底与失败摘要。

1.18.2.7 案例 7：跨 chat 广播（控制会话）

- 目标：在多个 chat 发布通知。
- 路径：权限检查 -> send_message(target_ch
- 失败点：非 control chat 调用。
- 修复：回退当前 chat 并提示权限不足。

1.18.2.8 案例 8：记住用户偏好并回读

- 目标：保存并验证偏好。
- 路 径 ： write_memory -> read_memory -> 回复确认。
- 失败点：信息过于模糊。

- 修复：要求用户提供可操作描述。

1.18.2.9 案例9:从长对话提取长期事实

- 目标：避免信息遗忘。
- 路径：reflector 定时提取 -> structured memory 注入。
- 失败点：提取噪声过多。
- 修复：提升质量闸门与分类规则。

1.18.2.10 案例10:子代理并行调研依赖风险

- 目标：分析依赖库安全与维护状态。
- 路径：sub_agent(task) -> 主代理整合。

- 失败点：子代理任务定义不清。
- 修复：加入输入边界和输出格式约束。

1.18.2.11 案例 11：检查 Web 配置风险

- 目标：判断当前部署是否安全。
- 路径：调用 self_check -> 解析 warning -> 给整改清单。
- 失败点：warning 信息太多。
- 修复：按高/中/低优先级输出。

1.18.2.12 案例 12：恢复失败的定时任务

- 目标：处理 DLQ 中断任务。
- 路径：list_scheduled_task_dlq -> replay -> 观察结果。
- 失败点：重放后再次失败。

- 修复：先修配置再重放，避免死循环。

1.18.2.13 案例 13: 自动化代码体检

- 目标：每日检查仓库关键指标。
- 路径：schedule -> bash(测试/静态检查) -> 输出简报。
- 失败点：命令波动大。
- 修复：拆成多个小任务并独立重试。

1.18.2.14 案例 14: 定位权限拒绝原因

- 目标：解释 Permission denied。
- 路径：检查 auth context -> control_chat_ids -> target_chat。
- 失败点：用户以为系统故障。

- 修复：输出清晰权限说明与申请路径。

1.18.2.15 案例 15：知识库链接失效修复

- 目标：扫描并修复文档坏链。
- 路径：glob(md) -> grep(http) -> web_fetch 验证。
- 失败点：网络抖动误判。
- 修复：二次验证 + 缓存失败样本。

1.18.2.16 案例 16：大型任务拆解失败

- 目标：任务太大，循环触顶。
- 路径：检测 max iterations -> 提示拆分。
- 失败点：用户继续大请求。

- 修复：自动提供拆分模板。

1.18.2.17 案例 17：工具连续失败后的用户沟通

- 目标：避免误导“已完成”。
- 路径：收集 failed_tools -> 透明反馈。
- 失败点：失败信息过于技术化。
- 修复：分“用户可执行动作”和“内部原因”两段输出。

1.18.2.18 案例 18：群聊上下文噪声过高

- 目标：提取与任务有关信息。
- 路径：消息窗口限制 -> 相关关键词过滤。
- 失败点：遗漏关键前文。

- 修复：允许用户指定“从某条消息开始”。

1.18.2.19 案例 19：跨平台消息分片不一致

- 目标：保持不同平台可读性。
- 路径：统一语义输出 -> 适配器分片。
- 失败点：段落断裂。
- 修复：按换行与标题边界切分。

1.18.2.20 案例 20：工具返回结构异常

- 目标：防止系统崩溃。
- 路径：ToolResult 规范化 -> 缺省字段补全。
- 失败点：error_type 缺失。

- 修复：运行时自动标注 `tool_error`。

1.18.2.21 案例 21: 沙箱 runtime 波动

- 目标：确认执行路径是否可靠。
- 路径：观测 fallback 计数 -> 策略调整。
- 失败点：误以为一直在沙箱。
- 修复：开启 `require_runtime` 并阻断发布。

1.18.2.22 案例 22: 记忆冲突更新

- 目标：用户偏好发生变化。
- 路径：显式记忆命令 -> `super-sede`。
- 失败点：旧记忆仍被注入。
- 修复：清理归档状态和优先级。

1.18.2.23 案例 23：技能使用时机错误

- 目标：避免无关技能污染流程。
- 路径：先 todo 再 activate_skill, 再执行。
- 失败点：技能滥用。
- 修复：在任务定义中明确触发条件。

1.18.2.24 案例 24：长文本输出中断

- 目标：完整输出报告。
- 路径：检测 max_tokens -> 提示继续。
- 失败点：用户误以为已结束。
- 修复：自动附“继续输出”建议语。

1.18.2.25 案例 25：外部网页抓取 超时

- 目标：快速给出阶段结果。
- 路径：web_fetch 超时 -> 提示部分结果。
- 失败点：全量失败导致无输出。
- 修复：先返回已抓取部分并标记缺口。

1.18.2.26 案例 26：模型返回空可见文本

- 目标：保证用户看到结果。
- 路径：runtime guard 重试一次。
- 失败点：重试后仍空。
- 修复：返回明确失败提示并建议重试。

1.18.2.27 案例 27：文件编辑竞态

- 目标：避免覆盖最新改动。
- 路径：read -> edit -> read 回检。
- 失败点：并发写入。
- 修复：增加唯一匹配约束与变更确认。

1.18.2.28 案例 28：高频任务导致告警风暴

- 目标：控制告警噪声。
- 路径：指标聚合 -> 阈值分级 -> 抑制策略。
- 失败点：每次失败都告警。
- 修复：按窗口聚合并设置恢复条件。

1.18.2.29 案例 29：升级后行为漂移

- 目标：快速验证核心契约。
- 路径：稳定性 smoke -> 比对关键指标。
- 失败点：只看功能是否能跑。
- 修复：把策略拒绝率和恢复率纳入验收。

1.18.2.30 案例 30：用户要求“全自动无确认执行”

- 目标：平衡效率与风险。
- 路径：保留审批门 + 提供批处理方案。
- 失败点：越权自动化。
- 修复：明确不能绕过安全边界。

1.18.3 18.3 模板化执行建议

对于多数复杂任务，你可以直接套用以下模板：

1. 用 `todo_write` 明确阶段目标。
2. 每阶段只选择必要工具。
3. 每阶段结束更新 `todo` 状态。
4. 阶段失败立即暴露，不隐瞒。
5. 最终总结包含“完成项 + 失败项 + 下一步”。

1.18.4 18.4 本章小结

案例工坊的核心不是“记住 30 个答案”，而是形成统一执行肌肉记忆：先计划、再执行、可见失败、可持续推进。

下一章将进入配置百科，把参数设计和故障模式逐项打通。

1.18.5 源码片段与图示

1.18.5.1 图示：计划与执行




Figure 15: Plan Execute

1.18.5.2 源码片段：todo 计划要求 (系统提示词节选, src/agent_engine.rs)

```
// Built-in execution playbook:  
// - If you will call any tool  
// or activate any skill in this  
// turn,  
// you must start by calling  
// todo_write to create a concise
```

```
task list.  
// - Keep exactly one task  
in_progress at a time.  
// - After each major step,  
update todo_write.
```

1.18.5.3 源码片段：工具失败汇总 提示（节选）

```
let final_text = if  
failed_tools.is_empty() {  
    final_text  
} else {  
    let tools =  
failed_tools.iter().cloned().collect::<Vec<  
    ">");  
    format!(  
        "{final_text}\n\nExecution  
note: some tool actions failed  
in this request ({tools})."  
    )  
};
```

1.18.6 实践误区速览

1. 读码只看函数，不画执行链和模块边界图。
2. 安全演练只做“通过性测试”，不做故障注入。
3. 复盘只记录结论，不沉淀可执行检查项。

1.19 第 19 章 配置项设计百科：意图、风险与反模式

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.19.1 19.1 阅读方式

本章按“配置项字典”形式展开。每个条目包含四个维度：

1. 设计意图：这个参数为什么存在。
2. 风险点：配置不当会出什么问题。
3. 推荐策略：常见环境下如何设置。
4. 反模式：最常见误配方式。

1.19.2 19.2 LLM 组

1.19.2.1 1) llm_provider

- 设计意图：抽象多家模型提供商。
- 风险点：provider 能力差异导致行为漂移。
- 推荐策略：生产固定 provider 并版本化。

- 反模式：在同环境频繁切换 provider 但无回归。

1.19.2.2 2) api_key

- 设计意图：统一 provider 凭据注入。
- 风险点：空值在某些 provider 下会启动失败。
- 推荐策略：通过环境注入并避免落盘明文。
- 反模式：把 key 直接提交到配置文件仓库。

1.19.2.3 3) model

- 设计意图：显式模型选择。
- 风险点：默认模型变化造成不可控升级。

- 推荐策略：生产固定模型名，升级走灰度。
- 反模式：依赖 provider 默认模型且无监控。

1.19.2.4 4) llm_base_url

- 设计意图：支持私有网关与兼容端点。
- 风险点：网关不兼容工具调用协议。
- 推荐策略：上线前做工具回合兼容压测。
- 反模式：替换网关后只测纯文本对话。

1.19.2.5 5) max_tokens

- 设计意图：限制单次输出长度。

- 风险点：过低导致关键信息截断。
- 推荐策略：按任务模板分层配置。
- 反模式：为了省钱统一设置很小上限。

1.19.2.6 6) max_tool_iterations

- 设计意图：限制循环失控。
- 风险点：过低无法完成复杂任务；过高耗时增加。
- 推荐策略：先保守高值，再用数据下调。
- 反模式：为了快把上限压到个位数。

1.19.3 19.3 上下文与记忆组

1.19.3.1 7) `max_history_messages`

- 设计意图：控制历史窗口规模。
- 风险点：窗口过大导致噪声堆积。
- 推荐策略：群聊比私聊更保守。
- 反模式：把它当“越大越聪明”指标。

1.19.3.2 8) `max_session_messages`

- 设计意图：触发压缩前的会话上限。
- 风险点：过高导致会话臃肿。
- 推荐策略：结合 `compaction` 观察延迟。
- 反模式：只调它，不调压缩保留量。

1.19.3.3 9) compact_keep_recent

- 设计意图：压缩后保留近期上下文。
- 风险点：过低丢失最近关键动作。
- 推荐策略：保持足够覆盖最近执行轨迹。
- 反模式：为了节省 token 把它设为极小。

1.19.3.4 10) memory_token_budget

- 设计意图：限制记忆注入成本。
- 风险点：预算过低导致“假失忆”。
- 推荐策略：配合注入日志迭代调优。

- 反模式：只看主观体验，不看注入统计。

1.19.3.5 11) reflector_enabled

- 设计意图：控制后台记忆提取开关。
- 风险点：关闭后长期记忆演进停滞。
- 推荐策略：生产默认开启。
- 反模式：因一次误提取就永久关闭。

1.19.3.6 12)

reflector_interval_mins

- 设计意图：平衡提取频率与成本。
- 风险点：间隔过短会增加系统负担。

- 推荐策略：按对话密度分环境设置。
- 反模式：统一高频而不看业务活跃度。

1.19.4 19.4 路径与隔离组

1.19.4.1 13) data_dir

- 设计意图：统一运行时数据根目录。
- 风险点：路径变化导致状态迁移混乱。
- 推荐策略：生产绑定稳定持久卷。
- 反模式：部署脚本每次生成新路径。

1.19.4.2 14) skills_dir

- 设计意图：可选覆盖技能目录。
- 风险点：与 data_dir 技能目录混用产生歧义。
- 推荐策略：团队内统一一种来源。
- 反模式：同环境多技能目录并存。

1.19.4.3 15) working_dir

- 设计意图：工具默认工作路径。
- 风险点：误指向系统敏感目录。
- 推荐策略：专用目录 + 权限最小化。
- 反模式：直接指向用户 home 根目录。

1.19.4.4 16)

working_dir_isolation

- 设计意图：共享或按 chat 隔离。
- 风险点：shared 模式跨会话污染。
- 推荐策略：多用户环境优先 chat。
- 反模式：为了方便全量使用 shared。

1.19.4.5 17) **timezone**

- 设计意图：调度时区统一。
- 风险点：时区错配导致任务错时执行。
- 推荐策略：显式配置并与团队约定一致。
- 反模式：依赖系统默认时区。

1.19.5 19.5 Sandbox 组

1.19.5.1 18) `sandbox.mode`

- 设计意图：控制执行隔离开关。
- 风险点：off 模式在高风险场景暴露宿主。
- 推荐策略：生产逐步迁移到 all。
- 反模式：认为开启一次后永远安全。

1.19.5.2 19) `sandbox.backend`

- 设计意图：后端选择（auto/docker）。
- 风险点：auto 下环境差异造成行为不一致。
- 推荐策略：关键环境固定后端并验收。

- 反模式：跨环境混用且不做自检。

1.19.5.3 20) `sandbox.image`

- 设计意图：指定容器执行镜像。
- 风险点：镜像依赖导致命令失败。
- 推荐策略：维护组织级基线镜像。
- 反模式：临时换镜像但不做回归。

1.19.5.4 21) `sandbox.container_prefix`

- 设计意图：容器命名隔离。
- 风险点：前缀冲突导致清理困难。
- 推荐策略：按环境设置唯一前缀。

- 反模式：多实例共用同前缀。

1.19.5.5 22) `sandbox.no_network`

- 设计意图：限制容器外联。
- 风险点：误关闭导致数据外传面扩大。
- 推荐策略：默认 true，按需放开。
- 反模式：为图省事全局关闭网络隔离。

1.19.5.6 23)

`sandbox.require_runtime`

- 设计意图：runtime 不可用时行为策略。
- 风险点：false 导致静默回退宿主。
- 推荐策略：生产设为 true。
- 反模式：不知道其值就上线。

1.19.5.7 24) `sandbox.mount_allowlist_path`

- 设计意图：显式挂载白名单。
- 风险点：缺失时挂载边界过宽。
- 推荐策略：配置并版本化管理。
- 反模式：上线后从不维护 allowlist。

1.19.5.8 25)

`sandbox.memory_limit`

- 设计意图：限制内存占用。
- 风险点：过小导致频繁 OOM。
- 推荐策略：按压测结果分层配置。
- 反模式：拍脑袋设置固定小值。

1.19.5.9 26) `sandbox.cpu_quota`

- 设计意图：控制 CPU 份额。

- 风险点：过低导致执行超时增多。
- 推荐策略：按任务类型设置范围。
- 反模式：所有环境统一极限压缩。

1.19.5.10 27) sandbox.pids_limit

- 设计意图：限制进程数。
- 风险点：某些工具链需要更多子进程。
- 推荐策略：先测后配，留安全余量。
- 反模式：不测试就设置过低。

1.19.6 19.6 Web 控制面组

1.19.6.1 28) web_enabled

- 设计意图：控制 Web 控制面开关。
- 风险点：无需求暴露额外攻击面。
- 推荐策略：不用就关闭。
- 反模式：默认开启却从不维护。

1.19.6.2 29) web_host

- 设计意图：绑定监听地址。
- 风险点：0.0.0.0 暴露公网风险。
- 推荐策略：默认 loopback, 公网需额外防护。
- 反模式：开发便捷配置直接复制到生产。

1.19.6.3 30) web_port

- 设计意图：控制入口端口。
- 风险点：与现有服务冲突。
- 推荐策略：纳入基础设施端口管理。
- 反模式：多实例共享同端口。

1.19.6.4 31) web_auth_token

- 设计意图：legacy token 鉴权。
- 风险点：单 token 粒度粗、轮换困难。
- 推荐策略：迁移到 scoped API key。
- 反模式：长期依赖单 token。

1.19.6.5 32) web_max_inflight_per_session

- 设计意图：控制会话并发。
- 风险点：过高导致资源争抢。

- 推荐策略：先低后高，逐步放量。
- 反模式：按峰值一次性放开。

1.19.6.6 33) web_max_requests_per_window

- 设计意图：窗口内请求限额。
- 风险点：过大导致突发洪峰。
- 推荐策略：结合窗口长度共同调参。
- 反模式：只调请求数不调窗口。

1.19.6.7 34)

web_rate_window_seconds

- 设计意图：限流时间窗口。
- 风险点：过短但额度高，等效放水。
- 推荐策略：与请求额度成比例设置。

- 反模式：为了“快”把窗口压太短。

1.19.6.8 35)

web_run_history_limit

- 设计意图：流式历史缓存上限。
- 风险点：过小影响回放，过大占内存。
- 推荐策略：按会话并发估算。
- 反模式：忽略历史面板需求。

1.19.6.9 36) web_session_idle_ttl_seconds

- 设计意图：闲置会话清理。
- 风险点：过低引发频繁锁抖动。
- 推荐策略：不少于用户常见停顿时长。
- 反模式：设得极短导致体验波动。

1.19.7 19.7 渠道与权限组

1.19.7.1 37) `control_chat_ids`

- 设计意图：定义跨 chat 操作特权。
- 风险点：配置过宽会放大误操作半径。
- 推荐策略：最小化，定期审计。
- 反模式：把所有 chat 都设成 control。

1.19.7.2 38) `channels.telegram.enabled`

- 设计意图：控制 Telegram 适配器开关。
- 风险点：误开导致无 token 启动异常。
- 推荐策略：按部署目标启用。

- 反模式：模板复制后忘记关闭未用渠道。

1.19.7.3 39) `channels.telegram.bot_token`

- 设计意图：Telegram 凭据。
- 风险点：泄露后可被接管。
- 推荐策略：密钥托管 + 定期轮换。
- 反模式：明文写入共享文档。

1.19.7.4 40) `channels.telegram.allowed_groups`

- 设计意图：群组白名单。
- 风险点：空列表即全开放。
- 推荐策略：生产用白名单精确控制。
- 反模式：不知道空列表语义。

1.19.7.5 41) `channels.discord.enabled`

- 设计意图：控制 Discord 适配器。
- 风险点：误启造成多渠道意外响应。
- 推荐策略：按环境显式启停。
- 反模式：所有渠道默认全开。

1.19.7.6 42) `channels.discord.allowed_channel`

- 设计意图：限制可响应频道。
- 风险点：未设会扩大响应范围。
- 推荐策略：仅开放业务频道。
- 反模式：测试期配置长期保留。

1.19.7.7 43)

`channels.web.enabled`

- 设计意图：统一 Web 频道启用位。

- 风险点：与 legacy web_enabled 混淆。
- 推荐策略：统一使用新字段。
- 反模式：新旧字段同时改，结果不可预期。

1.19.8 19.8 语音、技能与扩展组

1.19.8.1 44) voice_provider

- 设计意图：语音转写 provider 选择。
- 风险点：本地命令路径不可用。
- 推荐策略：先验证命令模板。
- 反模式：切换 provider 不做回归。

1.19.8.2 45) voice_transcription_command

- 设计意图：本地转写命令模板。

- 风险点：命令注入与依赖缺失。
- 推荐策略：固定模板并限制参数来源。
- 反模式：允许用户输入直接拼接命令。

1.19.8.3 46) clawhub_registry

- 设计意图：技能仓库地址。
- 风险点：不可信源带来供应链风险。
- 推荐策略：固定可信 registry。
- 反模式：临时切换未知源。

1.19.8.4 47) clawhub_token

- 设计意图：访问私有技能仓库。
- 风险点：token 泄露可导致越权下载。
- 推荐策略：最小权限 token。

- 反模式：高权限 token 长期不轮换。

1.19.8.5 48) clawhub_agent_tools_enabled

- 设计意图：是否开放 agent 侧 clawhub 工具。
- 风险点：开放后技能安装面扩大。
- 推荐策略：按治理能力决定是否开启。
- 反模式：开启后无审计。

1.19.9 19.9 费用与可观测组

1.19.9.1 49) model_prices

- 设计意图：成本估算映射表。
- 风险点：价格未更新导致成本误判。

- 推荐策略：定期同步真实价格。
- 反模式：把历史价格长期当真。

1.19.9.2 50) openai_api_key (转写等扩展场景)

- 设计意图：隔离语音能力凭据。
- 风险点：与主模型 key 混用造成权限不清。
- 推荐策略：按功能拆分 key。
- 反模式：一个 key 覆盖所有服务。

1.19.10 19.10 配置治理总原则

1. 把配置看作“系统行为编码”，不是部署杂项。
2. 每次改配置都要有变更理由和回滚路径。

3. 安全参数默认收敛, 效率参数逐步放开。
4. 参数调优要有观测数据支撑。
5. 将高风险配置纳入自动自检与发布门禁。

1.19.11 19.11 本章小结

本章将配置项从“字段列表”转化为“行为与风险映射”。理解配置的设计意图, 才能在不同部署环境中做出稳健决策。

下一章将以事故复盘形式, 展示如何用这些机制处理真实故障。

1.19.12 源码片段与图示

1.19.12.1 图示：配置与运行时关系




Figure 16: MicroClaw Architecture

1.19.12.2 源码片段：Config 结构字段（节选，src/config.rs）

```
#[derive(Clone, Debug,  
Serialize, Deserialize)]  
pub struct Config {
```

```

        #[serde(default =
"default_llm_provider")]
        pub llm_provider: String,
        #[serde(default =
"default_max_tool_iterations")]
        pub max_tool_iterations:
usize,
        #[serde(default)]
        pub sandbox: SandboxConfig,
        #[serde(default =
"default_control_chat_ids")]
        pub control_chat_ids:
Vec<i64>,
        #[serde(default =
"default_web_max_inflight_per_session")]
        pub
web_max_inflight_per_session:
usize,
    }

```

1.19.12.3 源码片段：默认值函数 (节选)

```
fn
default_max_tool_iterations() -
> usize { 100 }
fn
default_memory_token_budget() -
> usize { 1500 }
fn
default_web_rate_window_seconds()
-> u64 { 10 }
fn
default_reflector_interval_mins()
-> u64 { 15 }
```

1.19.13 实践误区速览

1. 读码只看函数，不画执行链和模块边界图。
2. 安全演练只做“通过性测试”，不做故障注入。

3. 复盘只记录结论, 不沉淀可执行检查项。

1.20 第 20 章 事故复盘与演练：从告警到恢复

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.20.1 20.1 复盘方法

本章采用统一复盘模板：

1. 事故现象。
2. 影响范围。
3. 根因分析。
4. 处置步骤。
5. 长期改进。

通过统一模板，团队可以把“个人经验”转成“组织知识”。

1.20.2 20.2 事故案例（20 例）

1.20.2.1 事故 1：请求成功率突降

- 现象：
slo.request_success_rate 连续低于阈值。
- 影响：多渠道请求失败增多。
- 根因：某次发布后工具策略误配，关键工具被阻断。
- 处置：回滚策略映射，重跑 smoke。
- 改进：把策略映射校验加入 CI。

1.20.2.2 事故 2：工具可靠性下降

- 现象：tool_reliability 下滑。

- 影响：任务完成率下降。
- 根因：外部命令超时预算过低。
- 处置：调高高方差工具超时。
- 改进：建立按工具分类的超时基线。

1.20.2.3 事故 3：scheduler 恢复率异常

- 现象：
scheduler_recoverability_7d 下降。
- 影响：定时任务漏执行。
- 根因：重启后部分任务状态未正确更新。
- 处置：手动 replay DLQ，修复状态迁移。
- 改进：增加重启恢复回归用例。

1.20.2.4 事故 4：沙箱误回退宿主

- 现象：日志出现大量 fallback。
- 影响：隔离边界弱化。
- 根因：docker runtime 不可用且 require_runtime=false。
- 处置：切换 fail-closed 并修复 runtime。
- 改进：发布门禁加入 runtime 可用性检测。

1.20.2.5 事故 5：跨 chat 误发消息

- 现象：消息发送到错误 chat。
- 影响：隐私与业务风险。
- 根因：control chat 白名单配置过宽。
- 处置：收缩白名单并补审计日志。

- 改进：control chat 变更双人审核。

1.20.2.6 事故 6：Web 控制面暴露

- 现象：外网可直接访问管理接口。
- 影响：潜在越权风险。
- 根因：web_host 配置为公网地址且防护缺失。
- 处置：回退到 loopback，外层代理加鉴权。
- 改进：自检高危项触发发布阻断。

1.20.2.7 事故 7：记忆污染导致行为异常

- 现象：模型反复复述错误行为。
- 影响：回答质量持续退化。

- 根因：反思写入了“故障复述”类记忆。
- 处置：清理污染记忆，补过滤规则。
- 改进：记忆质量审计仪表板上线。

1.20.2.8 事故 8：模型空可见回复增多

- 现象：用户看到空回复。
- 影响：交互失败。
- 根因：provider 输出结构变化。
- 处置：启用 guard 重试并加兼容处理。
- 改进：增加 provider 兼容回归测试。

1.20.2.9 事故 9：高频任务导致资源拥塞

- 现象：CPU 飙高，排队严重。
- 影响：系统整体延迟上升。
- 根因：多个 cron 任务配置过密。
- 处置：限流、降频、分批执行。
- 改进：调度配置增加频率守卫。

1.20.2.10 事故 10：hooks 输出过大

- 现象：hook 处理链路异常缓慢。
- 影响：请求时延增加。
- 根因：hook 返回过大 JSON。
- 处置：降低输出上限并压缩字段。
- 改进：为 hook 增加体积监控。

1.20.2.11 事故 11: 升级后配置字段歧义

- 现象：新旧字段冲突导致行为不可预测。
- 影响：渠道启停异常。
- 根因：legacy 与新 channels 混用。
- 处置：统一迁移到新字段。
- 改进：升级脚本输出冲突检测报告。

1.20.2.12 事故 12: MCP 调用雪崩

- 现象：外部服务慢导致主流程堆积。
- 影响：请求超时显著增多。
- 根因：并发与队列上限不足。

- 处置：启用 bulkhead 与断路器参数。
- 改进：建立每服务容量模型。

1.20.2.13 事故 13：日志不足难以追责

- 现象：事故后无法还原执行链。
- 影响：修复周期拉长。
- 根因：关键事件未结构化记录。
- 处置：补 AgentEvent 与工具日志字段。
- 改进：统一日志 schema。

1.20.2.14 事故 14：长任务反复触顶迭代上限

- 现象：多轮均提示 max iterations。
- 影响：任务无法收敛。

- 根因：缺少计划分解与中间收敛点。
- 处置：强制 todo 拆分再执行。
- 改进：复杂任务自动建议拆分模板。

1.20.2.15 事故 15：导出功能权限误配

- 现象：普通 chat 可导出非本 chat 内容。
- 影响：数据泄露风险。
- 根因：某版本授权校验回归。
- 处置：紧急 hotfix + 回归测试。
- 改进：权限矩阵测试纳入必跑。

1.20.2.16 事故 16：技能同步污染本地环境

- 现象：同步后技能行为异常。

- 影响：任务执行稳定性下降。
- 根因：来源不可信或 frontmatter 不规范。
- 处置：回滚技能目录，重新同步可信源。
- 改进：技能来源白名单与签名策略。

1.20.2.17 事故 17：数据库文件空间膨胀

- 现象：磁盘占用持续上升。
- 影响：I/O 性能下降。
- 根因：历史记录与日志未治理。
- 处置：归档与清理策略落地。
- 改进：容量告警与周期压缩计划。

1.20.2.18 事故 18：不同渠道行为不一致

- 现象：同请求在不同渠道结果差异明显。
- 影响：用户体验割裂。
- 根因：适配层绕过共享执行路径。
- 处置：回收分叉逻辑，统一走核心 loop。
- 改进：跨渠道一致性回归套件。

1.20.2.19 事故 19：审批流程被误解为失败

- 现象：用户把 approval_required 当错误。
- 影响：任务中断率上升。
- 根因：交互反馈不清晰。

- 处置：改进审批提示语与自动重试说明。
- 改进：审批事件可视化。

1.20.2.20 事故 20：告警太多导致疲劳

- 现象：团队忽视真实高危告警。
- 影响：故障发现延迟。
- 根因：阈值与分级设计不合理。
- 处置：重构告警分层与抑制规则。
- 改进：按业务影响重排告警优先级。

1.20.3 20.3 演练计划（季度版）

建议每季度至少执行一次演练组合：

1. 权限越权演练。

2. 沙箱 runtime 不可用演练。
3. 调度恢复与 DLQ 重放演练。
4. Web 鉴权与限流演练。
5. 记忆污染清理演练。

每次演练都应输出：时间线、证据、改进项、负责人、截止日期。

1.20.4 20.4 复盘文化建议

1. 复盘聚焦系统，不追责个人。
2. 结论必须可执行，可验证。
3. 每个改进项必须绑定 owner。
4. 未关闭改进项必须进入下一轮复盘。
5. 复盘文档应纳入知识库检索。

1.20.5 20.5 本章小结

事故复盘是运行时系统成熟的关键能力。它把“出问题再修”升级

为“可学习、可复用、可预防”的工程循环。

至此，扩展卷完成。全书最后将给出总总结与实践路线建议。

1.20.6 源码片段与图示

1.20.6.1 图示：调度与恢复




Figure 17: Scheduled Task Life-cycle

1.20.6.2 源码片段：失败写入 DLQ（节选，src/scheduler.rs）

```
if !success {
    if let Err(e) =
call_blocking(state.db.clone(),
move |db| {
    db.insert_scheduled_task_dlq(
        task.id,
        task.chat_id,
        &started_for_dlq,
        &finished_for_dlq,
        duration_ms,

    dlq_summary.as_deref(),
        );
        Ok(())
    })
    .await
    {
        error!("Scheduler:
failed to enqueue DLQ for task
```

```
#{}: {e}", task.id);  
    }  
}
```

1.20.6.3 源码片段：Runbook 对应工具（节选，docs/operations/Runbook.md）

- Inspect failed scheduler runs: use tool
`list\_scheduled\_task\_dlq` with `chat\_id`
- Replay pending failures: use tool
`replay\_scheduled\_task\_dlq` with `chat\_id`

1.20.7 实践误区速览

1. 读码只看函数，不画执行链和模块边界图。
2. 安全演练只做“通过性测试”，不做故障注入。

3. 复盘只记录结论，不沉淀可执行检查项。

1.21 第 21 章 全书总结：把 Agent 系统做成工程系统

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

MicroClaw 的实践可以归纳为一句话：让模型做决策，让运行时做约束，让系统做记忆，让运维做闭环。

如果你要从这本书带走三件事，建议是：

1. 先做执行闭环，再做能力扩张。

2. 先做可观测和可恢复, 再做自动化规模化。
3. 先做安全边界, 再做体验提速。

从项目代码和文档可以看到, MicroClaw 的价值并不在“某个炫目的单点特性”, 而在多个朴素机制的长期配合:

1. 统一 Agent Loop, 避免平台分叉。
2. 工具抽象统一, 策略检查前置。
3. 安全分层治理, 审批与隔离并行。
4. 记忆分层治理, 提取与注入可观测。
5. 调度与 DLQ 闭环, 支持长期自动化。

6. Runbook + SLO，把经验变成制度。

当我们讨论“从零构建”时，真正难的从来不是写出第一个可运行版本，而是把它变成一个长期可维护、可治理、可演进的系统。Micro-Claw 提供了一个现实可行的工程样本。

愿这本书成为你的起点：不是复制实现细节，而是掌握背后的设计原则，并在你的系统里落地成自己的方法论。

1.21.1 源码片段与图示

1.21.1.1 图示：全局架构收束




Figure 18: Closing Overview

1.21.1.2 源码片段：统一执行入口（节选，src/agent_engine.rs）

```
pub async fn
process_with_agent(
    state: &AppState,
    context:
AgentRequestContext<'_,>,
    override_prompt:
Option<&str>,
    image_data: Option<(String,
String)>,
) -> anyhow::Result<String> {
    let engine =
DefaultAgentEngine;
    engine
        .process(state,
context, override_prompt,
image_data)
        .await
}
```

1.21.2 实践误区速览

1. 读码只看函数, 不画执行链和模块边界图。
2. 安全演练只做“通过性测试”, 不做故障注入。
3. 复盘只记录结论, 不沉淀可执行检查项。

1.22 第 22 章 实战练习题库： 从入门到进阶的工程训练营

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.22.1 22.1 练习目标与方法

本章不再给“重复模板题”，而是给一套可落地的训练营。每个练习都满足四个条件：

1. 能在真实代码与配置上操作。
2. 有清晰的验收标准。
3. 有对应源码位置可对照。
4. 有失败场景与回滚思路。

建议执行节奏：

1. 每次只做 1 个练习，必须写 todo。
2. 每次练习都保留“执行记录 + 结论 + 改进项”。
3. 每做完 4 个练习，复盘一次共性问题。

1.22.2 22.2 训练地图（图示）




Figure 19: Plan Execute




Figure 20: Agent Loop Sequence




Figure 21: Scheduled Task Life-cycle

1.22.3 22.3 基础营（6 练）

1.22.3.1 练习 1: 识别一次请求的完整执行链

- 目标：从入站消息追踪到最终回复。
- 操作：

1. 阅读 `src/agent_engine.rs` 主流程。

2. 标注消息准备、提示词构建、工具循环、会话保存四段代码。
3. 手动画出状态转移图。
 - 验收：能解释 `tool_use` 与 `end_turn` 两种分支的差异。
 - 源码锚点：`src/agent_engine.rs`。

1.22.3.2 练习 2：验证 `max_tool_iterations` 收口行为

- 目标：确认循环触顶时系统不会协议损坏。
- 操作：
 1. 设置较低 `max_tool_iterations`。
 2. 构造需要多工具步骤的请求。

3. 观察返回是否包含“达到上限”提示，`session` 是否仍可恢复。
- 验收：下一轮请求不出现 `tool_result` 顺序错误。
- 源码锚点：`src/agent_engine.rs` 上限收口分支。

1.22.3.3 练习 3：验证工具执行策略前置校验

- 目标：确认策略在工具执行前生效。
- 操作：
 1. 阅读 `execute_with_auth`。
 2. 人工构造 `policy` 不满足场景。
 3. 观察错误类型是否为 `execution_policy_blocked`。

- 验收：工具实现未执行就被拦截。
- 源码锚点：`src/tools/mod.rs`, `crates/microclaw-tools/src/runtime.rs`。

1.22.3.4 练习 4：验证高风险审批门

- 目标：确认高风险工具具备审批节奏。
- 操作：
 1. 使用 web 或 control chat 场景触发 bash。
 2. 观察首次调用返回。
 3. 观察自动重试后是否可继续。
- 验收：能清楚解释“为何 first call 不是直接执行”。

- 源码锚点：src/tools/mod.rs 测试 approval_required。

1.22.3.5 练习 5：验证会话恢复优先级

- 目标：理解 session 与 DB 回退路径。
- 操作：
 1. 执行多轮对话。
 2. 人为破坏 session 内容。
 3. 观察是否回退到 DB 历史重建。
- 验收：系统在 session 异常时仍能处理请求。
- 源码锚点：src/agent_engine.rs session 分支。

1.22.3.6 练习 6：验证 todo 执行纪律

- 目标：确保多步骤任务有可视计划。
- 操作：
 1. 给出复杂任务。
 2. 检查是否先写 todo。
 3. 检查每步状态是否同步更新。
- 验收：任务结束时 todo 与实际结果一致。
- 源码锚点：系统提示词 `playbook (src/agent_engine.rs)`。

1.22.4 22.4 进阶营（8 练）

1.22.4.1 练习 7: 沙箱 fail-open 与 fail-closed 对比

- 目标：理解 `require_runtime` 的生产含义。
- 操作：
 1. 在无 docker 场景启用 `sandbox`。
 2. 分 别 设 置 `require_runtime=false/true`。
 3. 比较执行结果与日志。
- 验收：能给出环境分层推荐。
- 源码锚点：`crates/microclaw-tools/src/sandbox.rs`。

1.22.4.2 练习 8：挂载路径防护演练

- 目标：验证敏感目录与符号链接拦截。
- 操作：
 1. 尝试配置含 `.ssh` 的路径。
 2. 尝试配置符号链接路径。
 3. 观察校验错误。
- 验收：两类路径均被拒绝或告警。
- 源码锚点：`validate_mount_dir` 相关函数。

1.22.4.3 练习 9：记忆注入预算调优

- 目标：避免“记忆太少/太多”。
- 操作：

1. 对 同 一 任 务 用 不 同
memory_token_budget。
 2. 对比最终答复准确性与上下文
噪声。
 3. 记录 injection logs。
- 验收：得到适合当前业务的预算
区间。
 - 源 码 锚 点：
build_db_memory_context。

1.22.4.4 练习 10：记忆污染防护演 练

- 目标：理解反思提取的风险。
- 操作：
 1. 构造“错误行为复述”类文本。
 2. 观察 reflector 是否过滤。

3. 构造“纠正性 action item”文本，观察是否保留。

- 验收：能解释为何“坏事实”不能入长期记忆。
- 源码锚点：`should_skip_memory_poisoning_ris`

1.22.4.5 练习 11：调度失败恢复与 DLQ 回放

- 目标：把失败任务转为可恢复流程。
- 操作：
 1. 人工制造任务失败。
 2. 使用 `list_scheduled_task_dlq` 查看失败记录。
 3. 使用 `replay_scheduled_task_dlq` 重放。

- 验收：能追踪一次完整失败-回放-成功链。
- 源码锚点：src/scheduler.rs + docs/operations/Runbook.md。

1.22.4.6 练习 12：跨 chat 权限矩阵测试

- 目标：验证普通 chat 与 control chat 差异。
- 操作：
 1. 普通 chat 触发跨 chat 操作。
 2. control chat 触发同动作。
 3. 对比错误与成功路径。
- 验收：权限边界清晰、错误可解释。
- 源 码 锚 点 :
authorize_chat_access。

1.22.4.7 练习 13: Web 自检驱动配置整改

- 目标: 将 warning 转为执行项。
- 操作:
 1. 调用 `/api/config/self_check`。
 2. 按 severity 排序整改。
 3. 复查 warning 数量变化。
- 验收: 高风险 warning 清零。
- 源码锚点: `src/web/config.rs`。

1.22.4.8 练习 14: 跨渠道一致性回归

- 目标: 确保 Telegram/Discord/Web 行为一致。
- 操作:
 1. 设计同一请求用例。

2. 分渠道执行并记录差异。
 3. 区分“适配差异”与“核心逻辑差异”。
- 验收：核心语义一致，差异仅在传输层。
 - 源码锚点：src/channels/*, src/agent_engine.rs。

1.22.5 22.5 实战营（8 练）

1.22.5.1 练习 15：故障注入与回滚演练

- 目标：验证发布失败时的响应速度。
- 操作：
 1. 人为引入策略错误（测试环境）。
 2. 触发 smoke 失败。

3. 执行回滚并验证指标恢复。

- 验收：有完整时间线和责任分工记录。

1.22.5.2 练习 16：工具超时预算分层

- 目标：建立 per-tool timeout 配置。
- 操作：
 1. 收集 `bash/browser/web_fetch` 耗时分布。
 2. 配置 `tool_timeout_overrides`。
 3. 比较失败率变化。
- 验收：长尾超时下降且总耗时可控。

1.22.5.3 练习 17：子代理任务设计

- 目标：把子代理用于独立子问题而非泛化调用。
- 操作：
 1. 选一个研究型子任务。
 2. 明确输入边界与输出格式。
 3. 检查主代理整合结果质量。
- 验收：子代理输出可直接复用，且无越权动作。

1.22.5.4 练习 18：结构化记忆生命周期治理

- 目标：处理冲突记忆与归档策略。
- 操作：
 1. 写入旧事实，再写入更新事实。

2. 检查 supersede 关系。
 3. 验证检索是否优先最新事实。
- 验收：旧事实不再误导主要回答。

1.22.5.5 练习 19: Hooks 策略注入 演练

- 目标：在不改核心循环的前提下注入治理规则。
- 操作：
 1. 编写一个 BeforeToolCall hook。
 2. 限制高风险参数模式。
 3. 验证 block/modify 行为。
- 验收：策略生效且不影响其他工具流程。

1.22.5.6 练习 20: 指标到行动闭环

- 目标：从告警直接联动处置手册。
- 操作：
 1. 定义 4 个核心 burn alert。
 2. 为每个告警绑定 Runbook 步骤。
 3. 演练一次从告警到恢复的值守流程。
- 验收：值班成员无需口口相传也能完成处置。

1.22.5.7 练习 21: 升级兼容性验证

- 目标：验证配置迁移与行为稳定。
- 操作：

1. 从旧配置迁移到新字段。
 2. 跑稳定性 smoke。
 3. 比对权限、调度、沙箱关键路径。
- 验收：无关键行为回退。

1.22.5.8 练习 22：成本可视化与配额治理

- 目标：将模型成本纳入发布验收。
- 操作：
 1. 配置 `model_prices`。
 2. 跟踪 7 天成本曲线。
 3. 结合任务成功率做成本/收益评估。
- 验收：形成可执行的预算策略。

1.22.6 22.6 关键源码片段 (练习速查)

1.22.6.1 片段 A: 工具策略前置

```
if let Err(msg) =  
    validate_execution_policy(name,  
    self.sandbox_mode,  
    self.sandbox_runtime_available)  
{  
    return  
    ToolResult::error(msg).with_error_type("exe  
}
```

1.22.6.2 片段 B: 沙箱运行时不可用分支

```
if !self.backend.is_real() {  
    if  
    self.config.require_runtime {  
        bail!("sandbox is  
enabled but no docker runtime  
is available");  
    }
```

```

    }
    return
exec_host_command(command,
opts).await;
}

```

1.22.6.3 片段 C: 调度复用 Agent Loop

```

process_with_agent(
    state,
    AgentRequestContext {
        caller_channel:
&routing.channel_name,
        chat_id: task.chat_id,
        chat_type:
routing.conversation.as_agent_chat_type(),
    },
    Some(&task.prompt),
    None,
)
.await

```


1.22.6.4 片段 D：失败写入 DLQ

```
if !success {  
  db.insert_scheduled_task_dlq(  
    task.id,  
    task.chat_id,  
    &started_for_dlq,  
    &finished_for_dlq,  
    duration_ms,  
    dlq_summary.as_deref(),  
  )?;  
}
```

1.22.7 22.7 本章小结

训练题库的重点不是题目数量，而是让团队形成统一执行习惯：先约束边界，再收集证据，再做最小改动，再完成复盘闭环。

1.22.8 实践误区速览

1. 训练只追求题量, 不做证据链和验收闭环。
2. ADR 只写原则, 不绑定代码与运维动作。
3. 决策长期不复审, 导致文档与实现分叉。

1.23 第 23 章 设计决策备忘录：真实 ADR 清单与证据链

本章导读：本章围绕该主题展开，先交代问题背景，再说明实现与取舍，最后给出实践建议。

1.23.1 23.1 使用说明

本章改为“真实 ADR + 代码证据”的方式，不再使用模板化重复文本。每条 ADR 包含：

1. 决策问题。
2. 最终选择。
3. 取舍分析。
4. 代码证据或文档证据。
5. 未来调整触发条件。

1.23.2 23.2 核心 ADR（架构层）

1.23.2.1 ADR-01: 坚持共享 Agent Loop，不做平台分叉

- 决策：所有渠道统一走 `process_with_agent`。
- 原因：减少行为漂移和维护成本。

- 代价：适配器必须严格边界化，不能偷渡业务逻辑。
- 证据： `src/agent_engine.rs`、README 中“不要新增平台专属 agent loop”。
- 触发再评估：当某平台出现不可绕开的协议差异且无法通过适配层消化。

1.23.2.2 ADR-02：工具策略前置校验

- 决策：在 `execute_with_auth` 里统一做 `policy/risk/approval`。
- 原因：保证每个工具调用都经过同一安全入口。
- 代价：工具层扩展时需维护策略映射。

- 证 据 : `src/tools/mod.rs`
`execute_with_auth`。
- 再评估：若出现大量策略误拦截，需增强策略可配置性。

1.23.2.3 ADR-03：高风险工具走审批门

- 决策：`bash` 等高风险工具需审批流程。
- 原因：降低误操作与越权动作概率。
- 代价：交互会增加一次确认摩擦。
- 证 据 :
`require_high_risk_approval` 调用与相关测试。

- 再评估：当审批噪声过高影响效率时，需引入更细粒度风险模型。

1.23.2.4 ADR-04：会话优先恢复，历史回退兜底

- 决策：先读 session，异常时回退 DB 历史。
- 原因：优先保证连续执行，再保证可恢复。
- 代价：需要维护 session 数据完整性。
- 证据：src/agent_engine.rs 消息加载分支。
- 再评估：当 session 损坏率上升时，需完善校验与修复。

1.23.2.5 ADR-05：显式记忆命令 走快速路径

- 决策：识别“记住”指令并直接写结构化记忆。
- 原因：降低高频记忆请求延迟和 token 开销。
- 代价：需要质量闸门防止脏记忆进入。
- 证据：`maybe_handle_explicit_memory_command`
- 再评估：若误识别率高，需增强语义判定。

1.23.2.6 ADR-06：上下文压缩是 必须，不是可选优化

- 决策：超过阈值即压缩会话。
- 原因：避免上下文无限膨胀和重点信息淹没。

- 代价：压缩策略不当会丢信息。
- 证据：max_session_messages + compact_messages 路径。
- 再评估：当复杂任务中出现“压缩后失忆”时调整策略。

1.23.3 23.3 核心 ADR（安全与隔离层）

1.23.3.1 ADR-07: Sandbox 默认 off，但生产建议 all

- 决策：默认 sandbox.mode=off，提供快速启用与诊断。
- 原因：降低首配摩擦，兼顾落地速度。
- 代价：默认安全边界较弱。
- 证 据 ： docs/security/execution-model.md。

- 再评估：当生产采用率提升后可讨论默认策略上调。

1.23.3.2 ADR-08:

**require_runtime 支持
fail-closed**

- 决策：require_runtime=true 时无 runtime 即拒绝执行。
- 原因：避免“以为在沙箱，实际在宿主”。
- 代价：可用性下降，需要运维保障 runtime。
- 证据：crates/microclaw-tools/src/sandbox.rs。
- 再评估：当 runtime 稳定性不足时需引入高可用方案。

1.23.3.3 ADR-09：挂载路径必须做敏感组件与符号链接校验

- 决策：拒绝敏感路径和 symlink 组件。
- 原因：降低隔离绕过风险。
- 代价：某些灵活挂载场景受限。
- 证据：`validate_mount_dir`、`contains_symlink_component`。
- 再评估：当合法场景被频繁误拒绝时细化规则。

1.23.3.4 ADR-10：聊天作用域授权优先简洁规则

- 决策：普通 chat 仅操作自身，control chat 可跨域。

- 原因：最小可行权限模型，易审计。
- 代价：复杂协作场景权限粒度不足。
- 证据：authorize_chat_access 与 ToolAuthContext。
- 再评估：当多角色协作增多时扩展 RBAC。

1.23.3.5 ADR-11: Web 控制面走 scope 化授权路线

- 决策：从 legacy token 迁移到 session + API key + scope。
- 原因：便于权限拆分和密钥轮换。
- 代价：迁移期双轨维护复杂。
- 证据：docs/rfcs/0001-authn-authz-model.md。

- 再评估：legacy path 使用率足够低时彻底下线。

1.23.4 23.4 核心 ADR（记忆与调度层）

1.23.4.1 ADR-12：记忆采用双层模型（文件 + 结构化）

- 决策：同时保留 AGENTS.md 和 SQLite 结构化记忆。
- 原因：兼顾可读性与可检索治理能力。
- 代价：双写与一致性管理成本更高。
- 证据：README_CN 与 src/scheduler.rs。
- 再评估：当双层维护成本过高时需做抽象收敛。

1.23.4.2 ADR-13: Reflector 周期 提取长期记忆

- 决策：后台任务按间隔提取 durable facts。
- 原因：让记忆系统具备长期学习能力。
- 代价：可能引入噪声与污染。
- 证据：REFLECTOR_SYSTEM_PROMPT 与过滤函数。
- 再评估：提取噪声率持续上升时加强规则与评估。

1.23.4.3 ADR-14: 记忆注入受 token budget 约束

- 决策：注入内容受 memory_token_budget 控制并记录日志。

- 原因：避免挤占主任务上下文。
- 代价：预算过低会损失记忆召回。
- 证据：build_db_memory_context。
- 再评估：按任务类型引入动态预算策略。

1.23.4.4 ADR-15：调度失败必须进入 DLQ

- 决策：任务失败写入 DLQ 并支持 replay。
- 原因：把失败从终态变中间态。
- 代价：需要维护重放幂等与队列治理。
- 证据：insert_scheduled_task_dlq 与 Runbook。

- 再评估：DLQ 长期堆积时引入自动补偿策略。

1.23.4.5 ADR-16：调度执行复用 主 Agent Loop

- 决策：scheduler 不自建执行引擎。
- 原因：保持人工触发与定时触发语义一致。
- 代价：scheduler 受主 loop 复杂性影响。
- 证据：`src/scheduler.rs`
`process_with_agent(...)`。
- 再评估：当后台任务特性明显不同再考虑分层。

1.23.5 23.5 核心 ADR（可观测与运维层）

1.23.5.1 ADR-17：自检接口输出风险分级

- 决策： `/api/config/self_check` 输出 `warning + severity`。
- 原因：把风险显性化并可自动化消费。
- 代价：规则需持续维护，否则误报漏报。
- 证据： `src/web/config.rs`。
- 再评估：误报率高时增加上下文化建议。

1.23.5.2 ADR-18: SLO 不只看请求成功率

- 决策：增加 tool reliability 与 scheduler recoverability。
- 原因：Agent runtime 关键风险在执行链路而非 HTTP 表层。
- 代价：指标解释门槛更高。
- 证据：`docs/operations/Runbook.md`, `docs/observability/metrics.md`。
- 再评估：指标过多难维护时做精简聚焦。

1.23.5.3 ADR-19: 稳定性 smoke 进入交付门禁

- 决策：把关键回归纳入统一 smoke 套件。

- 原因：防止隐性契约回归进入主干。
- 代价：CI 时间增长。
- 证据：Runbook 中 Stability Gate 说明。
- 再评估：门禁过慢时优化并行与样本选择。

1.23.5.4 ADR-20: Runbook 必须绑定可执行工具

- 决策：每个操作建议都尽量映射到具体 API/工具。
- 原因：减少值班期间“知道原则但不会操作”。
- 代价：文档维护成本增加。
- 证据：Runbook 中 DLQ replay、metrics 查询指令。

- 再评估：当文档和实现漂移时建立自动校验。

1.23.6 23.6 关键代码证据片段

1.23.6.1 片段 1: 统一工具执行入口

```
if let Err(msg) =  
    validate_execution_policy(name,  
    self.sandbox_mode,  
    self.sandbox_runtime_available)  
{  
    return  
    ToolResult::error(msg).with_error_type("exe  
}  
if let Some(blocked) =  
    require_high_risk_approval(name,  
    auth) {  
    return blocked;  
}
```

1.23.6.2 片段 2: sandbox runtime 不可用分支

```
if !self.backend.is_real() {  
    if  
    self.config.require_runtime {  
        bail!("sandbox is  
enabled but no docker runtime  
is available");  
    }  
    tracing::warn!("sandbox  
enabled but docker unavailable,  
falling back to host");  
    return  
    exec_host_command(command,  
opts).await;  
}
```

1.23.6.3 片段 3: 调度失败写入 DLQ

```
if !success {  
    db.insert_scheduled_task_dlq(  

```

```
        task.id,  
        task.chat_id,  
        &started_for_dlq,  
        &finished_for_dlq,  
        duration_ms,  
        dlq_summary.as_deref(),  
    )?;  
}
```

1.23.7 23.7 图示与定位




Figure 22: System Architecture

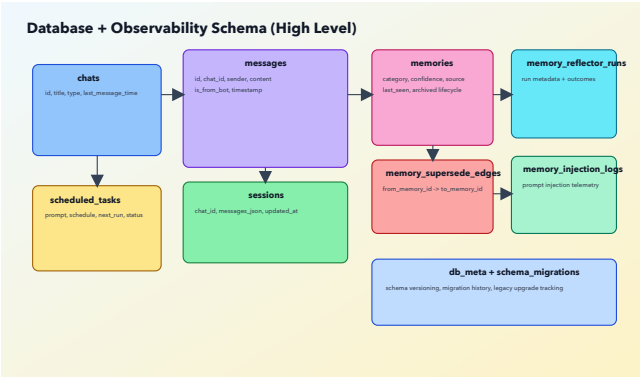


Figure 23: Database ER




Figure 24: New Tool Flow

1.23.8 23.8 本章小结

真正有价值的 ADR 不是“写了多少条”，而是每条都能对应到代码、测试、运维动作，并在演进中可持续修订。本章给出的 20 条决策，是 MicroClaw 当前工程化主干的可执行抽象。

1.23.9 实践误区速览

1. 训练只追求题量，不做证据链和验收闭环。
2. ADR 只写原则，不绑定代码与运维动作。
3. 决策长期不复审，导致文档与实现分叉。

1.24 附录

1.24.1 附录 A 术语表

1. Agent Loop: 由模型决策与工具执行组成的迭代闭环。
2. stop_reason: 模型本轮停止原因, 驱动状态转移。
3. ToolDefinition: 供模型调用的工具声明 (名称、描述、输入模式)。
4. ToolResult: 工具执行标准返回结构。
5. ToolRisk: 工具风险等级 (low/medium/high)。
6. ToolExecutionPolicy: 工具执行位置策略 (host-only/sandbox-only/dual)。

7. Approval Gate: 高风险操作审批门。
8. Control Chat: 可跨 chat 执行操作的受信会话。
9. WorkingDir Isolation: 工具工作目录隔离模式 (shared/chat)。
10. SandboxRouter: 决定宿主/容器执行路径的路由器。
11. Fail-open: 隔离依赖不可用时回退执行。
12. Fail-closed: 隔离依赖不可用时拒绝执行。
13. AGENTS.md: 文件记忆载体。
14. Structured Memory: 数据库结构化记忆。

- 15. Reflector: 后台记忆提取任务。
- 16. Memory Injection: 把记忆注入系统提示词的过程。
- 17. Token Budget: 注入内容的估算 token 上限。
- 18. Session Resume: 会话持久化恢复机制。
- 19. Context Compaction: 上下文压缩归档机制。
- 20. Todo Orchestration: 多步骤任务的计划-执行同步机制。
- 21. Scheduler: 定时任务执行器。
- 22. DLQ: 失败任务死信队列。
- 23. Hook: 生命周期策略扩展点。
- 24. BeforeLLMCall: 模型调用前 hook 事件。

- 25. BeforeToolCall: 工具调用前 hook 事件。
- 26. AfterToolCall: 工具调用后 hook 事件。
- 27. Self-check: 配置风险自检接口。
- 28. SLO: 服务级目标指标集合。
- 29. Burn Alert: SLO 消耗告警。
- 30. Capability Flags: 模型/提供商能力标识。

1.24.2 附录 B 工具清单与风险等级速查

1.24.2.1 B.1 内建工具列表（当前）

- 1. activate_skill
- 2. bash
- 3. browser

4. `cancel_scheduled_task`
5. `edit_file`
6. `export_chat`
7. `get_task_history`
8. `glob`
9. `grep`
10. `list_scheduled_task_dlq`
11. `list_scheduled_tasks`
12. `pause_scheduled_task`
13. `read_file`
14. `read_memory`
15. `replay_scheduled_task_dlq`
16. `resume_scheduled_task`
17. `schedule_task`
18. `send_message`
19. `structured_memory_delete`
20. `structured_memory_search`

- 21. structured_memory_update
- 22. sub_agent
- 23. sync_skills
- 24. todo_read
- 25. todo_write
- 26. web_fetch
- 27. web_search
- 28. write_file
- 29. write_memory

1.24.2.2 B.2 风险分级速查

- High

- 1. bash

- Medium

- 1. write_file
- 2. edit_file

3. write_memory
4. send_message
5. sync_skills
6. schedule_task
7. pause_scheduled_task
8. resume_scheduled_task
9. cancel_scheduled_task
10. replay_scheduled_task_dlog
11. structured_memory_delete
12. structured_memory_update

- Low

1. 其余未列入 high/medium 的工具默认 low。

1.24.2.3 B.3 执行策略速查（当前基线）

1. bash: dual

2. write_file: host-only
3. edit_file: host-only
4. 其余工具: host-only

1.24.2.4 B.4 子代理允许工具（受限工具集）

1. bash
2. browser
3. read_file
4. write_file
5. edit_file
6. glob
7. grep
8. read_memory
9. web_fetch
10. web_search
11. activate_skill
12. structured_memory_search

1.24.2.5 B.5 子代理默认禁用能力

1. `send_message`
2. `write_memory`
3. `schedule_task` 及其管理工具
4. `export_chat`
5. `sub_agent` (防递归)

1.24.3 附录 C 默认配置项速查表

1.24.3.1 C.1 LLM 与循环控制

1. `llm_provider`: `anthropic`
2. `max_tokens`: 8192
3. `max_tool_iterations`: 100
4. `max_history_messages`: 50
5. `max_session_messages`: 40
6. `compact_keep_recent`: 20
7. `compaction_timeout_secs`: 180
8. `memory_token_budget`: 1500

1.24.3.2 C.2 路径与运行目录

1. data_dir: 默认 ~/.microclaw
2. working_dir: 默 认
~/.microclaw/working_dir
3. working_dir_isolation: chat

1.24.3.3 C.3 沙箱默认值

1. sandbox.mode: off
2. sandbox.backend: auto
3. sandbox.image: ubuntu:25.10
4. sandbox.container_prefix:
microclaw-sandbox
5. sandbox.no_network: true
6. sandbox.require_runtime:
false
7. sandbox.mount_allowlist_path:
null
8. sandbox.memory_limit: null

- 9. `sandbox.cpu_quota: null`
- 10. `sandbox.pids_limit: null`

1.24.3.4 C.4 Web 默认值

- 1. `web_enabled: true`
- 2. `web_host: 127.0.0.1`
- 3. `web_port: 10961`
- 4. `web_max_inflight_per_session:`
`2`
- 5. `web_max_requests_per_window:`
`8`
- 6. `web_rate_window_seconds: 10`
- 7. `web_run_history_limit: 512`
- 8. `web_session_idle_ttl_seconds:`
`300`

1.24.3.5 C.5 调度与反思默认值

- 1. `timezone: UTC`

2. reflector_enabled: true
3. reflector_interval_mins: 15

1.24.3.6 C.6 超时预算默认值

1. default_tool_timeout_secs: 30
2. default_mcp_request_timeout_secs: 120

1.24.3.7 C.7 ClawHub 与语音默认值

1. clawhub_registry: <https://clawhub.ai>
2. clawhub_agent_tools_enabled: true
3. voice_provider: openai

1.24.3.8 C.8 配置调优备忘

1. 先确定部署画像，再调参数。

2. 先调整超时和限流, 再调整模型参数。
3. 先开启可观测, 再扩大自动化能力。
4. 高频变更参数应纳入变更审计。
5. 所有安全相关参数都应在自检接口中回看。

1.24.4 附录 D 参考资料与代码索引

1.24.4.1 D.1 项目与文档

1. 项目仓库: <https://github.com/microclaw/microclaw>
2. 官网: <https://microclaw.ai>
3. 作者: <https://github.com/everettjf>
4. 关键文档目录: `/Users/eevv/focus/microclaw/docs`

5. 网站内容目录： `/Users/eevv/
focus/microclaw/website`

1.24.4.2 D.2 关键源码索引

1. Agent Loop: `src/
agent_engine.rs`
2. 运行时装配: `src/runtime.rs`
3. 工具注册与策略校验: `src/
tools/mod.rs`
4. 子代理工具: `src/tools/
sub_agent.rs`
5. 调度器与反思器: `src/
scheduler.rs`
6. 配置定义: `src/config.rs`
7. 沙箱路由与后端: `crates/microclaw-tools/src/
sandbox.rs`

- 8. 工 具 运 行 时 策 略 :
crates/microclaw-tools/src/
runtime.rs
- 9. Web 配 置 自 检 : src/web/
config.rs

1.24.4.3 D.3 关键 RFC 与运维文档

- 1. Auth 模型 : docs/rfcs/0001-
authn-authz-model.md
- 2. Hooks 模型 : docs/rfcs/0002-
hooks-event-model.md
- 3. 运行手册 : docs/operations/
runbook.md
- 4. 执 行 模 型 : docs/security/
execution-model.md
- 5. 稳定性计划 : docs/operations/
stability-plan-2026-q1.md

1.24.4.4 D.4 博客索引

1. `/website/blog/2026-02-07-building-microclaw.md`
2. `/website/blog/2026-02-14-built-with-rust-microclaw-runtime.md`
3. `/website/blog/2026-02-19-microclaw-february-updates.md`